

深度研究报告

AI泡沫什么时候会爆

一条产业链的冷峻真相：

从万亿美元CAPEX到算力需求崩溃的拐点预测

产业链深度分析 | 财务数据验证 | 历史泡沫对比

全球格局变化 | AGI黑天鹅情景 | 投资策略框架

2026年6月

目录

摘要

研究背景与核心问题

核心发现四：三大黑天鹅

投资者行动框架

1.1 AI产业链的四层结构

1.2 资金传导链条

2.1 五大云厂商资本开支全景

2.2 资金来源：从自有资金到疯狂借债

2.3 AI收入vs CAPEX：惨淡的投入产出比

2.4 RPO缓冲器：CAPEX拐点的减速带

3.1 四大半导体巨头财务爆发

3.2 产业链涨价全景

3.3 泡沫信号：高估值与订单能见度

4.1 SpaceX/xAI：丑媳妇见公婆的第一个财报

4.2 OpenAI：收入增长但亏损扩大

4.3 Anthropic：被政府列为供应链风险

4.4 AI公司共同的盈利困境

5.1 算力租赁市场疯狂涨价

5.2 云厂商AI服务的利润真相

5.3 CoreWeave：煤矿中的金丝雀

6.1 供给端：产能释放时间表

6.2 需求端：训练与推理的结构裂变

6.3 Capex 增速拐点：泡沫破裂的关键信号

6.4 触发条件：五重压力矩阵

6.5 最可能情景：2027-2029年“软着陆”

7.1 2000年光纤泡沫：最像当前的历史参照

7.2 移动互联网周期：基建烧完，腾讯笑纳

7.3 铁路泡沫：更久远但本质相同的教训

8. 宏观环境：特朗普周期与利率风暴

8.1 特朗普政策的不确定性

8.2 利率与债市风险

8.3 经济衰退概率

9.1 AI应用商业化加速

9.2 谁是AI时代的大赢家？——从互联网基建泡沫的历史镜鉴说起

反面视角：赢家的不确定性

9.3 投资策略建议

10.1 核心结论

10.2 给投资者的行动框架

摘要

研究背景与核心问题

2023年至2026年，全球人工智能产业经历了一场史无前例的资本狂潮。五大云厂商（Amazon、Microsoft、Google、Meta、Oracle）2026年合计资本支出预计超过6000-7000亿美元（不同机构口径略有差异：Goldman Sachs估算约6000亿美元，Barclays估算约7850亿美元），同比增长约36%，其中AI基础设施独占约75%。然而，这笔巨额投资的商业回报却远未兑现：云厂商2026年AI直接收入仅250-433亿美元，投入产出比高达28:1。本报告通过对AI产业链12个维度的深度研究，回答一个核心问题：AI基础设施投资狂潮是否构成泡沫？如果是，何时、以何种方式破裂？破裂后谁将成为赢家？

核心发现一：投入产出失衡——投入产出比高达28:1

云厂商2026年CAPEX超7000亿美元，AI直接收入仅250-433亿美元，CAPEX覆盖率仅4-7%。Bank of America的计算显示，云厂商CAPEX已消耗运营现金流的94%。当CAPEX超过运营现金流时，公司必须借债或发股——目前五大云厂商已通过债务融资1210亿美元（同比增长4.3倍）。这形成了一个危险的资金循环：云厂商借债数千亿建数据中心→AI公司租用算力但无法盈利→云厂商AI服务收入远不足以覆盖CAPEX→半导体公司拿走大部分利润。NVIDIA毛利率75%，TSMC毛利率66%，而AI应用公司毛利率仅33%——上游半导体捕获了超过45%的全产业链利润，利润分配呈现“倒金字塔”格局。

核心发现二：丑媳妇已见公婆——xAI财报暴露AI商业模式真相

SpaceX S-1文件提供了AI前沿模型公司最详尽的财务画像。xAI 2026年Q1营收8.18亿美元，运营亏损24.7亿美元，亏损/收入比3.02:1。2025年全年，xAI营收32亿美元，运营亏损64亿美元，运营利润率为-200%——即每收入1美元就亏损2美元。PitchBook分析师Harrison Rolfes直言：“如果xAI的赌注成功，每月数十亿美元的烧蚀将被视为一笔便宜买卖；如果失败，我们将见证历史上最大的风险投资修正”。Starlink作为SpaceX唯一的盈利板块，Q1运营利润11.9亿美元，正被用于交叉补贴AI业务的巨额亏损。这是AI公司财务真相的首次公开暴露，也预示着后续OpenAI、Anthropic等公司的IPO将面临同样的审视。

核心发现三：泡沫破裂的精确时点——2027年Q2-Q3至2028年H1

泡沫破裂的量化信号是CAPEX 同比增速见顶回落——即增速本身开始放缓。当前市场定价的不是CAPEX绝对水平，而是其增速。当增速放缓时，高估值股票面临“增速溢价”的消退，引发估值压缩。基于以下数据，我们构建了三阶段预测模型：

阶段	时间	CAPEX 增速	增速方向	状态标识
加速期	2026年	60-88%	加速上行	当前状态
拐点期	2027年Q2-Q3	35-40%	见顶回落	高风险窗口
压缩期	2028年	10-25%	持续回落	泡沫收缩期

IDC预测AI基础设施支出2026年同比+53%（至4870亿美元），2029年将超1万亿美元（31% CAGR）。但Barclays的模型显示，虽然绝对金额将从2026年的7850亿美元增至2027年的1.16万亿美元，同比增速将显著放缓。连续两个季度CAPEX同比增速下降是我们定义泡沫进入高风险期的量化阈值。

重要修正——RPO缓冲器效应：Oracle \$5,530亿和Microsoft \$6,250亿的剩余履约义务（RPO）为CAPEX提供了2-3年的惯性支撑。这意味着CAPEX的绝对水平在2027-2028年仍将维持高位（情景A，40%概率），但增速的拐点取决于RPO增速何时放缓。新增监控指标：**RPO增速拐点——RPO领先CAPEX约2-3个季度**，若RPO增速开始放缓，CAPEX拐点就近了。

基于RPO分析，修正后的双情景预测：

情景	概率	CAPEX拐点时间	核心假设
情景A：RPO缓冲有效	40%	2028年H1	RPO增速维持高位（YoY>100%），订单积压持续支撑CAPEX
情景B：RPO开始失速（最可能）	50%	2027年Q2-Q3	RPO增速放缓，CAPEX失去"前瞻性燃料"
情景C：RPO大规模违约	10%	2027年H2	OpenAI等核心客户财务恶化触发连锁反应

需要强调的是，最可能的情景不是2000年式的崩盘，而是2027-2029年的“缓慢修正”——Capex增速从60%降至10-25%，估值压缩30-50%，部分项目取消，但不会出现系统性金融危机。区别在于，本轮泡沫的资助者拥有AAA级信用评级和超5000亿美元总运营现金流，提供了强大的“减震器”。2027年Q2-Q3是第一个关键观察窗口（若RPO增速未放缓则延至2028年H1）。

核心发现四：三大黑天鹅

第一，AGI递归自我改进。 Anthropic CEO Dario Amodei预测超人类AGI可能在2026-2027年出现，Google DeepMind CEO Demis Hassabis估计2030年前实现AGI的概率为50%。若模型能够自主优化架构，当前千亿美元级的训练CAPEX将面临断崖式贬值——这是对基础设施投资逻辑的根本性颠覆。

第二，AI核武器化（Fable 5出口管制）。 中美科技脱钩已使NVIDIA在华份额从95%跌至55%，中国AI芯片国产化率升至41%。四名美国参议员已要求FSOC调查AI债务风险。若出口管制全面升级导致全球市场分裂，基于全球统一市场的算力供给模型将彻底失效。

第三，宏观环境恶化。 10年期美债收益率维持在4.45%-4.56%的高位，特朗普关税政策的反复已使科技七巨头单日蒸发万亿市值。57%的机构将“科技泡沫破裂”列为2026年最大风险。AI泡沫的维持依赖低利率和高风险偏好——这两个条件正在系统性恶化。

投资者行动框架

监控四个领先指标：**CoreWeave股价**（纯AI基础设施公司的财务晴雨表，当前空头寸占流通股的12.20%）；**CAPEX 增速拐点**（连续两个季度增速下降为泡沫高风险信号）；**GPU租赁价格**（H100一年期合约价已从1.70涨至2.35美元/小时；此为合约价，现货价已从峰值约8美元回落，合约滞后于现货——二者背离本身即供需拐点信号）；**RPO 增速拐点**（新增——Oracle/Microsoft RPO领先CAPEX 2-3季度，若RPO增速放缓则拐点临近）。

关键区分：做空“AI基建泡沫”，做多“AI技术价值”。泡沫破裂后，已建成的算力基础设施将继续服务AI应用发展——正如光纤泡沫后97%的光纤一度闲置，但最终成为Google和Amazon的数据高速公路。历史规律高度一致：铁路泡沫后90%现代英国铁路网保留，移动基建烧完后腾讯和阿里崛起。本轮AI基建泡沫的终局不会不同——最大的受益者将是拥有生态优势的平台型企业（Microsoft、Google、字节跳动），而非纯基础设施公司。

情景	概率	触发条件	市场影响
乐观：AGI加速 / 泡沫延续	30%	新应用爆发、AGI突破拉动需求	CAPEX增速维持50%+，估值进一步扩张
最可能：软着陆（基准）	55%	CAPEX增速自然放缓至35-40%	估值压缩30-50%，无系统性危机
黑天鹅：硬着陆	15%	管制升级 / 宏观恶化 / AI公司暴雷	快速回调50%+，部分公司破产

对于投资者而言，关键不是在泡沫中猜测顶部，而是在泡沫破裂后站在正确的一边。2027年Q2-Q3是第一个关键观察窗口（若RPO增速未放缓则延至2028年H1）。

1. 产业链全景：从ChatGPT到万亿基建狂潮

2022年11月ChatGPT的发布，开启了一场人类商业史上罕见的资本支出狂潮。短短三年间，全球五大云厂商（hyperscaler）的年度资本支出（Capital Expenditure, CAPEX）从约2,300亿美元飙升至2026年预计的7,000亿美元以上，增幅超过三倍。这笔资金的流向揭示了AI产业链一个令人不安的真相：产业链上游的半导体公司捕获了绝大部分利润，中游的云厂商沦为“昂贵的中间商”，而下游的AI应用公司则普遍深陷亏损泥潭。上游基础设施层在整个产业链利润分配中占比高达45%，这一格局与传统的“微笑曲线”截然不同——AI产业链的利润不是向两端集中，而是向最顶端的芯片设计和制造环节单向汇聚。

1.1 AI产业链的四层结构

按资金流向自上而下，AI产业链可分为四个层级：应用层、平台层（模型公司）、基础设施层（云厂商）和硬件层（半导体）。终端用户的付费逐层向下传导，最终大部分沉淀到半导体；而每一层在利润分配中的地位却天差地别。

1.1.1 应用层：未来赢家尚未爆发

应用层是AI产业链的最下游，直接面向终端用户。当前的代表包括字节跳动（豆包AI，月活3.45亿）、腾讯（混元大模型）、阿里巴巴（通义千问）、Cursor（AI编程助手）以及Microsoft 365 Copilot（约2,000万付费席位）等。

应用层的核心特征是用户规模庞大但变现能力有限。以字节跳动的豆包为例，月活用户已达3.45亿，但单用户收入（ARPU）仍处于较低水平。AI Agent（智能体）市场预计在2026年达到109-121亿美元，但与基础设施层的万亿级投入相比，这一数字微不足道。

SemiAnalysis的研究指出，从2023-2025年，AI产业链的绝大部分价值被基础设施层捕获。应用层公司面临两大挑战：一是推理成本高企，难以实现规模化盈利；二是平台层公司（如OpenAI）正在向下游延伸，直接推出面向终端用户的产品（ChatGPT），与应用层形成竞争关系。

历史经验表明，基础设施过度建设最终将使应用层受益——铁路泡沫后铁路运输成为经济支柱，光纤泡沫后互联网应用蓬勃发展。AI的特殊性在于，云厂商（基础设施层）本身也在积极布局应用层（Microsoft Copilot、Google Gemini），这意味着它们可能同时捕获两层价值。

1.1.2 平台层：AI 公司提供模型 API 和云服务

平台层由OpenAI、Anthropic、xAI等AI模型实验室（model labs）构成。它们位于产业链的中间位置，向上游云厂商租用算力，向下游企业用户和应用开发者提供模型API和AI服务。

OpenAI是这一层的代表，也是“增收不增利”的典型案​​例。2025年年度经常性收入（Annual Recurring Revenue, ARR）达到200亿美元，同比增长233%。然而，高营收背后是高得惊人的成本——2026年预计运营亏损约140亿美元（non-GAAP口径；计入股票薪酬的GAAP净亏损预计达250-260亿美元，详见4.2节），同比增长约三倍。OpenAI的毛利率从2024年的40%降至2025年的33%，根本原因在于推理成本同比增长了四倍。根据内部财务文件，OpenAI预计不早于2029年实现盈利，2023-2028年累计预计亏损将达440亿美元。

值得注意的是，Anthropic的情况正在改善。其ARR从2025年的约90亿美元攀升至2026年中的约470亿美元（2026年4月约300亿、5月约470亿），推理基础设施毛利率从38%提升至70%以上。这一改善主要得益于

Agentic AI（智能体AI）推动的token需求激增，以及更高效的成本管理。Anthropic预计在2026年Q2首次实现单季营业利润盈利，为行业提供了一个相对乐观的参考。

平台层面临的核心矛盾在于：60-80%的收入需要用于购买算力，这使得即便收入高速增长，盈利仍然遥不可及。API定价的持续价格战进一步压缩了利润空间——OpenAI的GPT-4系列API价格在过去两年中下降了超过90%。

1.1.3 基础设施层：云厂商疯狂建设数据中心

基础设施层由五大云厂商主导——Amazon、Microsoft（Azure）、Alphabet（Google Cloud）、Meta和Oracle。它们是全球AI算力的主要供给者，也是本轮CAPEX狂潮的核心驱动力。2026年，五大厂商合计CAPEX预计达到6,600-7,500亿美元，其中约75%（约4,500-5,250亿美元）直接投向AI基础设施。

Amazon以2,000亿美元的2026年CAPEX指引位居榜首，Microsoft紧随其后达到1,900亿美元，Alphabet规划1,800-1,900亿美元，Meta将指引上调至1,250-1,450亿美元，Oracle则计划投入500亿美元。这些数字意味着，仅五家公司每年在AI基础设施上的投入，就超过了全球大多数国家的GDP。

云厂商的CAPEX主要流向三个方向：GPU和AI服务器采购（约占50-60%）、数据中心建设与电力配套（约占25-30%）、以及网络设备和冷却系统（约占10-15%）。其中，GPU采购的最大受益者是NVIDIA——前三大客户（包括Microsoft和Meta）在2025年上半年贡献了NVIDIA约34%的收入。

云厂商的财务处境颇为尴尬。尽管传统云业务仍保持较高盈利水平——AWS营业利润率约37.7%，Google Cloud营业利润率32.9%——但AI业务的盈利性正在快速恶化。AWS的利润率已从近40%的历史高位下滑至32-35%区间，Google Cloud虽然利润率改善，但绝对规模仍不足以覆盖庞大的CAPEX投入。CAPEX的激增推高了折旧费用，而AI服务的定价权却受制于激烈竞争——OpenAI在过去两年中将API定价下调超过90%，价格战的压力传导至整个产业链。Bank of America的数据显示，CAPEX已消耗云厂商运营现金流的94%（扣除股东回报后），这一比例在历史上前所未有。更值得关注的是，云厂商的资本密集度（CAPEX/营收）已从过去10年均值约15%攀升至2026年预计的33-57%，意味着每产生1美元收入就需要投入0.33-0.57美元的资本支出，这一水平更接近传统公用事业公司，而非轻资产的科技公司。

1.1.4 硬件层：半导体公司享受历史级景气

硬件层是AI产业链中利润最丰厚的环节，由NVIDIA、TSMC（台积电）、Broadcom和Marvell等公司主导。这一层的核心特征是极高的进入壁垒和定价权，形成了事实上的双寡头垄断格局：NVIDIA控制芯片设计，TSMC控制芯片制造。

NVIDIA是AI浪潮中利润捕获能力最强的公司。FY2025（截至2025年1月）营收达到1,305亿美元，同比增长114%；毛利率高达75%（GAAP），营业利润达815亿美元，同比增长147%。数据中心业务贡献了1,152亿美元收入，同比增长142%，占总收入的88%。NVIDIA的定价权来源于CUDA生态系统的锁定效应——CUDA已成为AI领域事实上的“操作系统”，配合GPU市场约80%的份额，形成了难以逾越的护城河。

TSMC则是制造环节的绝对垄断者。Q1 2026营收达357亿美元，同比增长35.1%；Q4 2025毛利率62.3%，超出自身指引的59-61%区间；先进制程（7nm及以下）市场份额超过90%，全球约99%的AI加速器由其制造。TSMC的HPC（含AI）业务收入占比已达58%（2025全年），NVIDIA是其最大客户，贡献约22-25%收入。

Broadcom和Marvell作为芯片设计领域的“第二梯队”，同样享受着AI红利。Broadcom的AI芯片业务（主要为Google定制TPU）快速增长，Marvell则凭借数据中心互联芯片（DCI）和定制AI芯片业务获得市场青睐。

AI产业链四层结构与资金流向



AI产业链四层结构与资金流向

1.2 资金传导链条

AI产业链的资金流动形成了一个危险的闭环：云厂商借债数千亿美元建设数据中心，AI公司租用算力但无法盈利，终端用户支付的费用大部分流向半导体公司，而云厂商的AI服务收入远不足以覆盖CAPEX。这个循环的可持续性完全取决于资本市场的耐心。

1.2.1 “云厂商借钱→买GPU→半导体赚钱→AI公司烧钱”的闭环

资金链条的起点是资本市场。2025年，五大云厂商发行了约1,210亿美元债券，较2020-2024年均值280亿美元增长4.3倍。这些资金的大部分直接流向了半导体公司——云厂商CAPEX的约75%用于购买AI基础设施，其中GPU和服务器采购占据最大份额。

NVIDIA是这一传导链条的最大受益者。FY2025数据中心收入1,152亿美元，平均每个季度约288亿美元。这意味着NVIDIA每季度的收入相当于OpenAI全年的收入规模。TSMC同样受益显著，AI加速器制造几乎为其独有业务，毛利率持续超出自身指引。

AI公司处于资金链条的中间环节，扮演着“烧钱者”的角色。OpenAI 2026年预计运营亏损约140亿美元（non-GAAP），意味着其每月消耗超过11亿美元。这些亏损的资金最终也流向了半导体公司——OpenAI收入的60-80%用于算力采购，而其算力采购的主要对象正是使用NVIDIA GPU的云厂商。

表1：AI产业链各环节利润分配与盈利能力对比

产业链环节	代表公司	毛利率	营业利润率	利润分配占比	盈利状态
芯片设计	NVIDIA	75%	57%	~25%	高盈利
芯片制造	TSMC	62-66%	54%	~20%	高盈利
云服务商	AWS/Azure/GCP	68-70%	20-35%	~30%	整体盈利，AI业务承压
AI模型公司	OpenAI/Anthropic	33-70%	负值	~10%	普遍亏损
服务器组装	工业富联	6.76%	3.9%	~5%	微利
终端用户	企业/消费者	—	—	最终买单者	—

上表数据揭示了一个极端不平衡的利润分配格局。上游半导体公司（NVIDIA + TSMC）合计捕获了产业链约45%的利润，而处于中游、承担最大资本开支的云厂商仅获得约30%。最底层的AI模型公司和服务器组装商则几乎无法留存利润。工业富联2025年云计算板块营收达6,027亿元人民币，占比66%，但毛利率仅为5.73%，公司整体利润率仅3.9%。这一利润率水平与NVIDIA的75%毛利率形成了超过十倍的差距。

1.2.2 终端用户买单的钱，90%流向了半导体公司

资金在产业链各层级的传导效率极低。以一条典型的资金路径为例：企业用户向AI应用公司（如OpenAI）支付100美元的API调用费用，其中约60-80美元用于购买算力；这笔算力费用进入云厂商（如Azure）的收入，但其中约70-80%又用于采购GPU和服务器；最终，约50-60美元流入了NVIDIA和TSMC的口袋。

云厂商的CAPEX与AI直接收入之间的鸿沟，进一步印证了这一投入产出失衡的存在。2026年五大厂商CAPEX合计约7,000亿美元，但AI直接收入仅为约250-370亿美元，覆盖率仅约4%。这意味着每投入100美元CAPEX，仅能产生约4美元的AI直接收入回报。Sequoia Capital的David Cahn提出的“6000亿美元问题”正是对这一矛盾的尖锐概括——全球AI年投资超过6,000亿美元，但实际产生的收入仅约1,000亿美元，缺口持续扩大。更严峻的是，这一投入产出失衡具有自我强化的特征：云厂商为了不被竞争对手甩开，被迫持续增加CAPEX；而CAPEX的增加进一步推高了对GPU的需求，使NVIDIA得以维持高定价；高定价又加剧了AI公司的亏损，使整个产业链的盈利能力进一步恶化。

表2：云厂商CAPEX与AI直接收入对比（2026年预测）

公司	2026年CAPEX（亿美元）	AI直接收入运行率（亿美元）	CAPEX/收入比	资金缺口覆盖率
Amazon	2,000	~269	7.4x	13.5%
Microsoft	1,900	~370	5.1x	19.5%
Alphabet	1,850	~200	9.3x	10.8%
Meta	1,350	自有使用（无直接收入）	N/A	N/A
Oracle	500	~49	10.2x	9.8%
合计	~6,600	~888（含云总收入）	~7.4x	~13.5%

Meta的情况最为特殊——其CAPEX主要用于内部AI研发和社交媒体的AI功能集成，而非对外提供AI服务，因此没有直接的AI服务收入对冲。剔除Meta后，其余四家厂商CAPEX合计约5,250亿美元，对应AI相关收入约888亿美元（含广义云收入），覆盖率约为17%。即便采用最宽泛的收入定义，CAPEX的投入产出比仍然处于历史罕见的低水平。

1.2.3 产业链利润分配表：各环节毛利率与净利率对比

产业链利润分配失衡的根本原因在于各环节市场结构和议价能力的巨大差异。NVIDIA和TSMC分别控制着芯片设计和制造的“瓶颈环节”，形成了双重护城河。云厂商为了竞争被迫进行“军备竞赛”式CAPEX，导致议价能力被严重削弱——它们不得不接受NVIDIA的GPU定价，否则将在AI服务竞争中落后。AI应用公司则面临推理成本高企和API价格战的双重挤压。

这种利润分配格局在短期内（2-3年）难以改变。NVIDIA的CUDA生态锁定效应和TSMC的先进制程垄断地位都不是短期内可以被打破的。云厂商的自研芯片（如Google TPU、Amazon Trainium）虽然正在推进，但市场份额仍然有限——Amazon Trainium芯片已出货约140万颗，但与NVIDIA每年数千万颗的出货量相比仍有显著差距。

高盛的分析指出，半导体公司独赚AI价值的格局是不可持续的，因为下游尚未产生足够利润来养活整个产业链。判断胜负的关键变量只有一个：AI创造的新利润池，能不能大到同时养活模型实验室、云厂商、半导体公司和服务器组装商。如果这一利润池的增长不及预期，当前的利润分配格局将面临调整压力——最可能的调整方向是半导体公司的毛利率压缩，以及部分高杠杆云厂商的CAPEX收缩。

然而，SemiAnalysis持相对乐观的观点，认为从2025年底开始，AI实验室正在从基础设施层手中接管价值捕获。Anthropic毛利率从38%提升至70%以上的改善，以及Agentic AI推动的token价值提升，为这一观点提供了支撑。但无论价值如何转移，当前产业链的核心矛盾——CAPEX规模与AI收入之间的巨大缺口——在短期内不会有根本性改变。

2. 云厂商CAPEX分析：千亿美元的豪赌

2024-2026年正在成为人类商业史上一场史无前例的资本支出狂潮。五大云厂商合计CAPEX从2024年的约2,300亿美元飙升至2025年的约4,430亿美元，再到2026年预计的6,600-7,500亿美元（部分机构预测甚至达8,300亿美元）。这一数字意味着仅一年时间内的资本开支增幅高达60-88%，而两年间增长超过三倍。更值得关注的是，这些CAPEX的资金来源正在发生根本性转变——从过去依赖充裕的经营现金流，转向大规模的债务融资。Bank of America的研究显示，CAPEX已消耗云厂商运营现金流的94%（扣除股东回报后），2025年五大厂商发行债券达1,210亿美元，较2020-2024年均值增长4.3倍。这场千亿美元的豪赌，其可持续性将决定AI泡沫的命运走向。

2.1 五大云厂商资本开支全景

2.1.1 2024-2026年CAPEX数据表

五大云厂商的CAPEX增长轨迹呈现出惊人的一致性——每一家都在以历史最高速度扩张基础设施投资。

表1：五大云厂商2024-2026年CAPEX详细数据

公司	2024年CAPEX	2025年CAPEX	2026年指引	2025-2026同比增速	占2026E营收比重
Amazon	~\$830亿	~\$1,283亿	~\$2,000亿	+56%	~57%
Alphabet	~\$525亿	~\$850亿	\$1,800-1,900亿	+111-124%	~45%
Microsoft	~\$557亿(FY2024)	~\$887亿(FY2025)	~\$1,900亿	~+115%	~48%
Meta	~\$392亿	~\$722亿	\$1,250-1,450亿	+73-101%	~52%
Oracle	~\$142亿(FY2024)	~\$250亿+(est.)	~\$500亿	+100%	~57%
合计	~\$2,350亿	~\$4,000-4,430亿	\$6,600-7,500亿	+60-88%	~33%

注：以上数据口径包括现金CAPEX+融资租赁。Oracle财年为6月结束，其他为日历年。


Amazon是2026年CAPEX计划的绝对领导者，其2,000亿美元计划占五大厂商总和的近30%。2026年2月该指引发布后，Amazon盘后股价暴跌11%，投资者担忧自由现金流将转负。Amazon的CAPEX投向高度集中于AWS AI基础设施，其自研Trainium芯片已出货140万颗，试图降低对NVIDIA的依赖。

Microsoft经历了最剧烈的财务转型，从一家轻资产的软件公司变成全球最大的重资产基础设施投资者之一。FY2025全年CAPEX达887亿美元，较FY2024的557亿美元增长59%。2026年日历年指引1,900亿美元，较分析师预期的1,546亿美元高出约350亿美元。其中约三分之二投向GPU和CPU，用于Azure和Copilot基础设施。

Alphabet在2026年的CAPEX增速是五大厂商中最激进的之一，几乎在2025年基础上翻倍。Google Q1 2026 CAPEX达357亿美元，同比增长超过100%。更令人瞩目的是，CFO Anat Ashkenazi表示2027年CAPEX将”significantly increase”（显著增加），这意味着CAPEX增速在2027年不会放缓。

Meta的CAPEX增速在相对意义上最为惊人。从2023年的280亿美元跃升至2026年的中值1,350亿美元，三年增长近五倍。CEO Zuckerberg在2026年4月被问及ROI迹象时，回应”that’s a very technical question”，这一模糊的表态引发了市场对其支出合理性的担忧。每次上调CAPEX后，Meta盘后股价都下跌6-10%。

Oracle是本轮AI基建潮中风险最高的公司，但也是增长最快的云基础设施提供商。FY2026 CAPEX指引500亿美元，意味着从FY2024的142亿美元实现3.5倍增长。为释放资金投向CAPEX，Oracle已裁减30,000名员工，预计释放60-80亿美元年度运营成本。



五大云厂商CAPEX三年对比

2.1.2 同比增速分析：2026年五大厂商合计CAPEX超7,000亿美元

2026年五大厂商CAPEX合计预计达到7,000-7,850亿美元，同比增速60-88%。S&P Global Ratings在2026年5月发布报告中预测，到2029年CAPEX将达1万亿美元。这一增速在历史上极为罕见——即便是2000年互联网泡沫时期，电信公司的CAPEX增速也仅在30-40%区间。

值得注意的是，所有云厂商均一致表示“产能受限而非需求受限”（demand-constrained, not supply-constrained）。AWS积压订单（backlog）达3,640亿美元（环比增长49%），Google Cloud积压达4,620亿美元（接近翻倍），Microsoft表示GPU容量已被预定至使用寿命结束（约6年）。这些数字构成了看多派的核心论据——需求信号真实且强劲，CAPEX的扩张是对真实市场需求的响应。

然而，看空派的反驳同样有力。历史上每次大规模基建狂潮——光纤、铁路、电力——最终都以产能过剩和大量破产告终。1990年代末的光纤网络建设导致5,000亿美元投资中绝大部分化为泡影，23家主要电信公司破产，纳斯达克电信指数暴跌92%。当前的CAPEX增速远超当时，而AI直接收入仅为CAPEX的约4%，投入产出比失衡程度有过之而无不及。

2.1.3 CAPEX占运营现金流比例：已攀升至94%，自由现金流即将转负

CAPEX对云厂商现金流的侵蚀已达到危险水平。Bank of America计算显示，CAPEX已消耗运营现金流的94%，而10年均值仅为40%。这一比例的飙升意味着云厂商几乎将所有经营产生的现金都投入了基础设施建设，股东回报（回购和分红）被迫大幅削减。

更严峻的是自由现金流（Free Cash Flow, FCF）的崩溃。Pivotal Research和Barclays的预测显示，2026年五大厂商中将有至少两家（Amazon和Oracle）的FCF转为负值，其余三家FCF将暴跌28-90%。

表2：五大云厂商自由现金流与CAPEX对比（2025-2026年）


公司	2025年FCF	2026年预测FCF	同比变化	2026年CAPEX	FCF覆盖CAPEX?
Microsoft	~\$716亿	~\$520亿	-28%	\$1,900亿	否，缺口\$1,380亿
Alphabet	~\$733亿	~\$82亿	-89%	\$1,850亿	否，缺口\$1,770亿
Amazon	~\$112亿	-\$170至-280亿	转负	\$2,000亿	否，严重为负
Meta	~\$436亿	~\$50亿	-90%	\$1,350亿	否，缺口\$1,300亿
Oracle	-\$25亿	更深度为负	恶化	\$500亿	否，严重为负

数据来源：Pivotal Research、Barclays、Bank of America预测

Amazon的FCF变化最为触目惊心。TTM FCF从2024年的382亿美元暴跌至2025年的112亿美元，2026年预计转为负170-280亿美元。这意味着Amazon将历史上首次在运营层面出现“烧钱”状态，必须通过债务融资来维持CAPEX计划和日常运营。

Alphabet和Meta的FCF预计将分别暴跌约89%和90%。Evercore ISI已发出警告，云厂商12个月远期FCF已”跌至2022年周期低点的黄旗水平以下”，行业正接近”红旗时刻”——即整体现金流可能转负的拐点。

云厂商财务压力全景：CAPEX吞噬现金流



云厂商财务压力全景

2.2 资金来源：从自有资金到疯狂借债

随着CAPEX吞噬运营现金流，五大云厂商的融资模式正在发生根本性转变——从过去依赖充裕的经营现金流，转向大规模的债务融资。这一转变的规模和速度在历史上前所未有。

2.2.1 债务融资规模：2025-2026年五大云厂商发行债务超1,210亿美元

Bank of America Securities研究显示，五大云厂商2025年债券发行达1,210亿美元，较2020-2024年均值280亿美元增长4.3倍。预计2026年发行额将达1,400亿美元，未来三年年均1,400亿美元。这一发行节奏将使五大云厂商与美国六大银行并列为投资级（IG）指数最大发行方。

传统上依赖经营现金流资助CAPEX的科技巨头，正转变为“杠杆化基础设施运营商”，类似于公用事业公司。这一转型的核心驱动力在于CAPEX增速远超经营现金流增速——当CAPEX超过运营现金流时，公司必须借债或发股来弥补缺口。

JPMorgan预测，未来五年科技行业债务发行将达1.5万亿美元。Morgan Stanley的估计更为激进，预计仅2026年云厂商债券发行就将达4,000亿美元。如此规模的债务供应已经产生了市场影响：云厂商债券利差相对于同级别其他行业发行人明显扩大，CDS对冲活动激增，AI相关新债发行溢价平均约12个基点，是更广泛IG市场2.5个基点均值的近5倍。

大规模发债的信用风险已开始浮现。Pimco首席投资官Mohit Mittal警告：“任何大规模CAPEX周期最终都可能导致过度投资风险”。中东冲突后能源价格上升可能推高通胀，限制美联储降息空间，进一步增加云厂商的融资成本。

2.2.2 Oracle的极端案例：债务1,346亿美元，评级仅BBB

Oracle是本轮AI基建潮中财务状况最令人担忧的云厂商。截至2026年，Oracle的总债务达到1,346亿美元，债务股本比（debt/equity）高达415%，另有2,480亿美元的表外租赁承诺。Q3 FY2026利息支出达9.78亿美元（占营收5.7%），同比增长11%。Moody's已警告其杠杆可能推高至4倍EBITDA，自由现金流已转为负247亿美元（TTM）。

Oracle的信用状况在五大厂商中明显落后。S&P Global给予Oracle的评级为BBB（负面展望），而Microsoft为AAA，Alphabet为AA+，Amazon为AA，Meta为AA-。这一评级差距直接反映在融资成本上——Oracle发行新债的利率显著高于其他四家厂商。

为应对财务压力，Oracle在2026年计划通过债务加股权融资450-500亿美元，其中约一半为股权（含200亿美元ATM股票发行计划）。已裁减30,000名员工以释放60-80亿美元年度运营成本转投CAPEX。

Oracle的客户集中风险同样不容忽视。剩余履约义务（RPO）达5,530亿美元（同比增长325%），其中约58%来自OpenAI。这意味着Oracle的收入高度依赖单一客户——如果OpenAI的财务状况恶化（2026年预计运营亏损约140亿美元，non-GAAP），Oracle的收入可见性将面临重大冲击。四名美国参议员已要求FSOC（金融稳定监督委员会）调查AI债务风险。

Rothschild对Oracle给出“卖出”评级，目标价暗示40%下行空间。Oracle股价从2025年9月峰值345美元暴跌57%至146美元，市场正在用脚投票惩罚高杠杆加高CAPEX的模式。

2.2.3 融资结构变化：从AAA级公司债到高风险垃圾债的转变

五大云厂商的融资结构正在发生变化。历史上，科技巨头以AAA或AA评级发行低利率投资级债券。但随着债务规模激增和FCF恶化，评级机构开始重新审视这些公司的信用状况。

S&P Global在2026年5月的报告中明确指出：“如果预期的现金流改善未能实现，紧张的资产负债表可能对评级构成风险”。该机构已开始调整云厂商债务计算口径，将表外融资义务纳入评估。这意味着未来评级下调的可能性正在上升。

Microsoft是唯一能以经营现金流覆盖大部分CAPEX的公司。FY2025经营现金流1,010亿美元，FCF 716亿美元，虽然较历史峰值有所下降，但财务缓冲空间仍然最大。这也是Microsoft能够保持AAA评级的原因。

相比之下，Alphabet的债务在2025年翻了两番，Amazon的2025年FCF从382亿美元暴跌至112亿美元，Meta发行了史上最大非并购类IG债券300亿美元。这些信号表明，即便是财务状况最好的科技巨头，也在承受前所未有的杠杆压力。

融资结构的变化不仅影响云厂商自身，还对整个债券市场产生溢出效应。JPMorgan预测未来5年1.5万亿美元科技债务发行，如此大规模的供应可能推高整个IG市场的信用利差。在当前中东冲突导致能源价格上涨、通胀预期升温的背景下，美联储若被迫维持高利率，云厂商的债务成本将进一步攀升，形成恶性循环。

2.3 AI收入vs CAPEX：惨淡的投入产出比

尽管云厂商在CAPEX上投入了数千亿美元，AI直接收入与之相比仍然微不足道。这一惨淡的投入产出比，是评估AI泡沫可持续性的核心指标。

2.3.1 云厂商AI服务收入：Azure AI运行率370亿、AWS 150亿、Google Cloud 200亿

各云厂商披露的AI相关收入数据存在定义差异，但即便采用最宽泛的定义，收入规模与CAPEX投入之间仍存在巨大鸿沟。

Microsoft的AI收入透明度最高。Q3 FY2026披露AI年化收入运行率达370亿美元，同比增长123%。Azure云收入约267亿美元/季度，同比增长40%，其中AI服务贡献了16个百分点的增长。Copilot付费席位超过2,000万。这些数据使Microsoft在AI变现方面走在行业前列。

Amazon的AWS AI收入运行率约150亿美元以上（Q1 2026），AWS总收入376亿美元/季度，同比增长28%。Amazon还披露其自研芯片（Trainium/Graviton）收入运行率超过200亿美元。AWS积压订单达3,640亿美元，需求端信号强劲。

Alphabet的Google Cloud收入200亿美元/季度（Q1 2026），同比增长63%，其中GenAI产品收入增长800%。Gemini月活用户达7.5亿以上。CFO Anat Ashkenazi在2026年4月上调CAPEX指引的同时，表示2027年CAPEX将”显著增加”，表明管理层对收入前景的信心。

Meta的AI收入主要通过广告业务间接体现——广告收入550亿美元/季度（同比增长33%），其中AI推荐系统被认为是增长的核心驱动力。Meta AI月活用户达6亿以上。Oracle的OCI云基础设施收入49亿美元/季度（同比增长84%），AI基础设施收入增长243%。

2.3.2 CAPEX覆盖率仅4-7%：每投入100美元仅收回4-7美元AI收入

表3：AI收入与CAPEX覆盖率分析（2026年预测）

指标	狭义定义（直接AI收入）	广义定义（含AI驱动的云收入增长）
五大厂商CAPEX合计	~\$7,000亿	~\$7,000亿
全球AI直接收入	~\$250-370亿	~\$433-888亿
CAPEX收入覆盖率	约4-5%	约6-13%
云基础设施市场规模（Q3 2025）	\$1,026亿/季度	—
年增长率	25%+	—

上表揭示了AI投入产出比的核心矛盾。即便采用最宽泛的收入定义（将所有云收入增量都归因于AI），CAPEX覆盖率也仅为6-13%。这意味着云厂商每投入100美元CAPEX，仅能通过AI服务收回约6-13美元收入。

Bank of America的计算更为悲观：AI相关服务产生约250亿美元直接收入，对应400亿美元以上的年度基础设施支出，覆盖率约4%。CNBC 2026年2月的报道也指出，AI服务的直接收入相对hyperscaler数千亿美元级资本开支的覆盖率仅个位数，巨额现金消耗已亮起红灯。

云厂商对这一低覆盖率的辩护逻辑是：CAPEX投资的是未来10年的基础设施，而非仅为了当前的AI收入。它们将当前的投资类比为2008年云计算初期的CAPEX——当时AWS的回报率同样受到质疑，但如今AWS年运行率达1,500亿美元，全球云市场超过万亿美元。

更进一步，“投入产出比28:1”这一指标本身的口径值得给多头一个完整的反驳：CAPEX形成的是可用6-10年的固定资产，而“AI直接收入”只是单一年度的窄口径数字，两者直接相除会系统性放大“缺口”。若改用年化口径——把CAPEX按6年折旧摊销（约每年1,100-1,200亿美元），再叠加AI驱动的广义云收入增量——“覆盖率”会从个位数跳升至数倍。多头由此主张：真正该考核的是“资产生命周期内的累计回报”，而非“单年CAPEX/单年收入”。本报告承认这一反驳的合理性，但仍持保留：其前提是这些资产能在6-10年内维持高利用率与定价权，而本报告第7章与4.5节将论证，GPU的代际报废速度与推理成本的指数级坍塌，恰恰是这一前提最脆弱的环节。

然而，这一类比存在两个关键差异。其一，2008年云计算CAPEX的规模远小于当前——即便是按通胀调整，当时的年度CAPEX也仅为当前的十分之一左右。其二，2008年云计算的单位经济学已经得到验证——按需计算的成本显著低于企业自建数据中心。而当前AI服务的单位经济学（unit economics）——尤其是推理成本与定价之间的关系——尚未得到充分验证。OpenAI 2025年推理成本同比增长四倍，而API定价却持续下降，这一矛盾表明AI服务的盈利能力仍面临重大不确定性。

2.3.3 分析师分歧：“投资未来” vs “烧钱无底洞”

市场对CAPEX的可持续性存在根本性分歧，看多和看空双方各有论据。

看多派的核心论据包括：需求信号真实且强劲——所有云厂商一致表示“产能受限而非需求受限”；云业务盈利能力强劲——AWS运营利润率37.7%，Google Cloud运营利润率从一年前的17.8%大幅提升至32.9%；长期结构性趋势不可逆——全球企业AI从试验阶段转向规模化生产部署。Goldman Sachs的观点代表了看多派的主流判断：2026年全球AI CAPEX超过5,000亿美元，但AI CAPEX占GDP比重仅0.8%，低于历史峰值1.5%，因此从宏观角度看并不过度。

看空派的反驳同样有力：AI直接收入仅250-370亿美元 vs CAPEX 7,000亿美元 = 4%覆盖率；每投入8-10美元仅产生1美元收入，ROI高度不确定；历史上每次大规模基建狂潮都以破产和整合告终。MIT的研究显示，约95%投资AI的企业未看到有意义的投资回报（该比例口径存在争议），42%的企业因ROI不明确而放弃AI项目（2024年仅17%）。

这一分歧的本质在于时间框架的不同。看多派关注的是5-10年的长期回报，认为当前的CAPEX是在为未来的万亿级AI市场奠定基础。看空派关注的是1-2年的短期现金流压力，认为CAPEX的增速不可能无限持续，一旦增速放缓，高估值股票将面临严重的估值压缩。

市场对CAPEX的心理转变在2026年上半年已经发生。2025年末，市场对CAPEX增长表示欢迎；2026年1-2月，Amazon 2,000亿美元公告引发第一波恐慌；2026年4月，Microsoft、Meta、Google同时上调CAPEX引发约1万亿美元市值蒸发；2026年5月，市场进一步分化——Google因Cloud收入强劲（+63%）获得认可，Meta因ROI叙事模糊而遭抛售。

这种心理转变的信号意义不容忽视。当市场从“欢迎CAPEX增长”转向“质疑CAPEX回报”时，云厂商通过借债维持CAPEX的能力将受到限制。一旦债权人或股东对AI ROI的耐心耗尽，CAPEX增速的放缓将不可避免——而这正是本报告核心论点的触发条件：泡沫将在CAPEX增速拐点时破裂。

2.4 RPO缓冲器：CAPEX拐点的减速带

前述分析似乎描绘了一条清晰的CAPEX减速路径：AI收入覆盖率低→现金流恶化→增速放缓→泡沫拐点。然而，这一推理忽略了一个关键变量——剩余履约义务（Remaining Performance Obligation, RPO）对CAPEX支出的“惯性支撑”。

2.4.1 RPO数据的震撼性

RPO是云厂商与客户签订的、尚未确认收入的未来合同金额，可视为云服务的“预订单”。2026年初的RPO数据揭示了一个关键事实：云厂商的订单积压已达到历史最高水平。

公司	RPO (2026年)	YoY增速	最大客户占比	RPO/CAPEX比
Oracle	\$5,530亿	+420%	OpenAI ~58%	11.1x
Microsoft	\$6,250亿	+110%	OpenAI ~45%	3.3x
Amazon (AWS)	\$3,640亿	+49%	分散	1.8x
Alphabet	\$4,620亿	~+100%	分散	2.5x

Oracle的RPO数据尤为引人注目——\$5,530亿的剩余履约义务是其2026年CAPEX指引（\$500亿）的11倍，且同比增长420%。表面上看，这意味着Oracle未来数年的收入已经“锁定”，为其CAPEX提供了强大的需求侧保障。

2.4.2 四个关键混淆：RPO ≠ CAPEX刚性保障

然而，将高RPO直接等同于CAPEX不会放缓，存在四个根本性的逻辑混淆：

混淆一：RPO是收入端，CAPEX是支出端。RPO衡量的是客户承诺未来购买云服务的金额（收入前瞻指标），CAPEX衡量的是厂商购买GPU和建数据中心的投入（支出指标）。两者方向不同、性质不同。高RPO说明未来收入可见性好，但不等于必须按原速CAPEX——厂商完全可以在收入增长的同时优化CAPEX效率（用更少的投入产生更多的收入）。

混淆二：签了GPU订单 ≠ 数据中心必须按时建成。NVIDIA的GPU订单排至2027-2028年，这仅仅是GPU的交付时间表，而非数据中心的建成时间表。数据中心项目可以延期、分期建设、调整规模。历史案例：2022-2023年因供应链延迟，多家云厂商的数据中心项目被推迟6-12个月，但RPO并未因此取消。

混淆三：RPO不是刚性承诺，可以取消。RPO合同通常包含退出条款——客户可以支付违约金后取消剩余合同。当AI需求放缓时，客户宁愿付违约金也不会继续购买不需要的服务。2020年疫情期间Zoom的RPO在后续正常化后大幅缩水，证明了RPO的脆弱性。更关键的是，Oracle RPO的58%来自OpenAI，而OpenAI自身2026年预计亏损\$140-260亿——这是典型的循环融资结构：Oracle借钱给OpenAI，OpenAI用Oracle的钱购买Oracle的云服务，形成互相支撑的“镜像风险”。

混淆四：RPO增速才是真正的领先指标。当前RPO的绝对值虽然高，但如果RPO增速开始放缓，CAPEX拐点就近了。RPO是“需求的前瞻指标”，CAPEX是“需求的滞后指标”——RPO领先CAPEX约2-3个季度。2026年

Oracle RPO增速仍高达420%，但如果2027年增速降至100%以下，即使绝对值仍在增长，CAPEX的"燃料"已经在减少。

2.4.3 修正后的双情景预测

综合RPO缓冲器的分析，我们将CAPEX拐点的单一时间点预测修正为双情景框架：

情景	概率	核心假设	CAPEX拐点时间
情景A：RPO缓冲有效	40%	RPO增速维持高位（YoY>100%），订单积压持续为CAPEX提供惯性支撑	2028年H1
情景B：RPO开始失速	50%	RPO增速放缓（YoY降至50%以下），新客户签约减少，已有RPO不足以维持CAPEX增速	2027年Q2-Q3
情景C：RPO大规模违约	10%	OpenAI等核心客户财务恶化导致大规模违约，触发连锁反应	2027年H2

情景A的核心逻辑是：Oracle \$5,530亿和Microsoft \$6,250亿的RPO确实为CAPEX提供了2-3年的"底部支撑"。即使管理层想要减速，已签订的供应链合同和数据中心建设义务也会推动CAPEX继续。在这种情景下，CAPEX的绝对水平在2027-2028年仍将维持高位，但增速仍将在2027年出现放缓——只是放缓的幅度更温和，拐点时间延后约2-3个季度。

情景B（最可能情景）的核心逻辑是：RPO增速本身就是均值回归的。Oracle RPO从\$1,000亿跃升至\$5,530亿（+420%）是不可持续的——随着基数增大，即使绝对增量不变，增速也会自然下降。当RPO增速从三位数降至两位数时，CAPEX增速将失去最重要的"前瞻性燃料"。

新增关键监控指标：除CAPEX 增速拐点外，新增监控RPO增速拐点。如果连续两个季度RPO同比增速下降，即使绝对RPO仍在增长，也应视为CAPEX拐点临近的预警信号——因为RPO领先CAPEX约2-3个季度。

3. 半导体爆发：神之宝座上的隐忧

AI投资狂潮的货币化终点，截至目前仍牢牢指向产业链最上游的半导体环节。当云厂商们以数千亿美元资本开支（Capital Expenditure, CAPEX）展开军备竞赛时，芯片设计商与晶圆代工厂正坐收渔利——NVIDIA的毛利率维持在75%的软件公司水平，台积电（TSMC）的毛利率创下66%的历史新高，Broadcom的AI半导体收入同比翻倍有余。这种利润高度集中的格局，构成了当前AI产业链最显著的结构特征：上游半导体公司捕获了超过45%的全产业链利润，而中游云厂商和下游AI应用公司则普遍面临亏损或微薄利润。

然而，神之宝座上并非没有隐忧。供应承诺已锁定至2031年，新产能却将在2026年下半年开始释放；前瞻市盈率（Forward P/E）从23倍到41倍分化严重，部分估值已透支多年增长；Google TPU、Amazon Trainium等自研芯片（Application-Specific Integrated Circuit, ASIC）正悄然侵蚀NVIDIA的市场份额。本章将深入分析四大半导体巨头的财务爆发、产业链涨价全景，以及隐藏在繁荣数据背后的泡沫信号。

3.1 四大半导体巨头财务爆发

3.1.1 NVIDIA：数据中心收入占比92%，毛利率75%，但供应承诺锁定至2031年

NVIDIA于2026年5月发布的2027财年第一季度报（截至2026年4月26日），以一份堪称“史诗级”的财报再次确认了其在AI基础设施领域的绝对统治地位。当季营收达创纪录的816亿美元，同比增长85%，环比增长20%，大幅超出华尔街预期的788亿美元。其中，数据中心收入752亿美元（同比增长92%，环比增长21%），占总营收的92.2%——这意味着NVIDIA已几乎完全蜕变为一家AI基础设施公司。

更具说服力的是利润端的表现。GAAP毛利率74.9%，non-GAAP毛利率75.0%，维持在软件公司级别的盈利水平；GAAP净利润583亿美元（同比增长211%），non-GAAP净利润455亿美元（同比增长139%）。Blackwell架构的规模化生产并未带来利润率压缩，反而通过网络收入（同比增长199%至148亿美元）进一步优化了利润结构。

展望下一季度，NVIDIA给出的营收指引为910亿美元（ $\pm 2\%$ ），同比增长约93%，年化收入运行率超过3,600亿美元。值得注意的是，指引中明确未假设任何来自中国的数据中心计算收入——这意味着即便在美国对华芯片出口管制持续收紧的背景下，NVIDIA的增长预期依然不受实质影响。

不过，NVIDIA的“超级碗时刻”背后也埋藏着巨额的财务承诺。截至2026年4月26日，公司的制造、供应和产能承诺总额从上一季度的约503亿美元飙升至1,190亿美元，其中950亿美元将在2027财年剩余时间内支付，剩余部分将在2028至2031财年支付。这一规模空前的产能锁定确保NVIDIA在2027年及以后的供应安全，但也意味着公司正在将巨额预付款绑定于一个长达五年的需求假设。

客户结构方面，NVIDIA在FY2027 Q1首次实现了超大规模客户（微软、Meta、谷歌、亚马逊、甲骨文）仅占数据中心收入约50%的结构多元化，其余50%来自AI云服务商、工业、企业和主权AI客户。这一变化在一定程度上缓解了市场对客户集中度风险的担忧，但前五大客户合计贡献仍不可忽视。

3.1.2 TSMC：毛利率66%创历史新高，CAPEX 520-560亿美元，3nm/2nm排产至2027年

台积电（TSMC）作为全球最大的晶圆代工厂，正享受着AI芯片需求爆发带来的历史性红利。2026年Q1，TSMC实现营收359亿美元（同比增长40.6%，环比增长6.4%），超出指引区间上限；毛利率66.2%、营业利润

率58.1%、净利润率50.5%，三项指标均创下历史最高水平。66.2%的毛利率意味着TSMC每生产一块芯片，就能保留超过三分之二的收入作为毛利——这种定价权在全球制造业中极为罕见。

TSMC将2026年CAPEX指引设定为520-560亿美元，较2025年实际支出的409亿美元增长27-37%，创公司历史新高。其中70-80%投向先进制程（2nm、3nm），10-20%投向先进封装（CoWoS等）。在产能排产方面，3nm产能已完全订满至2027年，2nm（N2）于2026年初进入大规模量产，目标Q4月产能6万片，每片2nm晶圆报价高达30,000美元。苹果占据50-55%的初始产能分配，AMD占12-15%。

从客户结构看，NVIDIA约占TSMC收入的22-25%（最大单一客户），苹果约占25%，两大客户合计贡献近一半收入。HPC（高性能计算，含AI）已取代智能手机成为TSMC最大的收入驱动因素，占2025年总收入的58%。公司管理层预计，AI芯片收入在2029年前将保持每年超过50%的复合增长率（CAGR）。

3.1.3 Broadcom：AI半导体收入同比翻倍，六大客户锁定至2028年，Forward P/E 38-41x

Broadcom在定制AI芯片（Custom ASIC）领域占据着约70%的市场份额，是NVIDIA之外AI半导体赛道最大赢家。FY2026 Q2（截至2026年5月），公司实现总营收221.87亿美元（同比增长48%），其中AI半导体收入达108亿美元（同比增长143%），超出市场预期。CEO Hock Tan在财报会上首次披露六大AI客户名单：Google（TPU）、Meta（MTIA）、OpenAI、Anthropic及两家未披露的超大规模客户，并指引2027年AI芯片收入超过1,000亿美元。

在订单能见度方面，Broadcom FY2026 Q2的AI积压订单（Backlog）价值约730亿美元，预计在未来18个月内交付。公司已与Meta将合作延长至2029年（初始承诺超过1吉瓦计算容量），与Google的TPU和网络供应协议延至2031年，Anthropic已签约2027年起使用3.5吉瓦TPU AI容量。Deutsche Bank更预测Broadcom FY2027 AI收入将达1,250亿美元，FY2028将达约1,900亿美元。

然而，Broadcom的客户集中度风险极高——前3-4大AI客户占据AI收入的绝大部分。FY2026 Q2财报发布后，因CEO未上调2027年1,000亿美元指引，市场反应负面，股价一度下跌14%。这一事件揭示了市场对Broadcom增长预期的脆弱性：即便143%的同比增长也未能满足投资者已被抬高的期望。

3.1.4 Marvell：数据中心占比76%，获NVIDIA 20亿美元战略投资

Marvell Technology虽然体量小于前三者，但正凭借光通信互连和定制芯片（XPU）两大引擎快速崛起。FY2027 Q1（截至2026年5月2日），公司实现营收24.18亿美元（同比增长28%），其中数据中心收入18.3亿美元（同比增长27%），占总收入的76%。

Marvell的增长指引极为激进：FY2027全年营收上调至约115亿美元（同比增长40%），FY2028目标上调至约165亿美元（同比增长45%），定制芯片业务目标FY2029超过100亿美元。更具战略意义的是，NVIDIA向Marvell投资约20亿美元获得战略股权，合作围绕硅光子学、NVLink Fusion集成和AI-RAN基础设施三大支柱展开。这一投资既是对Marvell在互连领域技术地位的认可，也为NVIDIA提供了供应链多元化的战略保障。

以下表格汇总了四大半导体巨头的核心财务指标：

指标	NVIDIA	TSMC	Broadcom	Marvell
最新季度营收	816亿美元	359亿美元	222亿美元	24.2亿美元
营收同比增速	85%	40.6%	48%	28%
数据中心/AI收入占比	92%	58% (HPC)	~49% (AI半导体)	76%
毛利率	75.0%	66.2%	77.0%	59.0%
Forward P/E	~23x	~24x	~38-41x	~33x
2026年CAPEX/供应承诺	1,190亿美元	520-560亿美元	—	—
订单能见度	至2031年	至2027年	至2028年	至2029年 (目标)
前瞻市盈率 vs 行业中位数	低于28.5x	低于28.5x	高于28.5x	高于28.5x

图3-1 四大AI半导体巨头核心财务指标对比（2026年）




图3-1 四大AI半导体巨头核心财务指标对比

上图清晰呈现了四家公司之间的估值分化。NVIDIA以85%的营收增速和75%的毛利率，Forward P/E仅约23倍，实际上低于半导体行业中位数28.5倍，PEG（市盈率相对盈利增长比率）约0.54倍。TSMC以24倍的Forward P/E提供最为稳健的估值锚。相比之下，Broadcom的41倍Forward P/E已显著超出行业中位数，隐含了市场对FY2027 AI收入超1,000亿美元这一雄心目标的充分定价。Marvell的33倍Forward P/E虽然绝对值不低，但相对于其40-45%的营收增长目标仍具备合理性。这种估值分化表明，市场并非对AI半导体板块进行无差别定价，而是在个股层面进行了差异化的增长预期折现。

3.2 产业链涨价全景

AI半导体巨头的财务爆发并非孤立现象，而是整个产业链全面涨价的结果。从存储芯片到晶圆代工，从光模块到半导体材料，一个前所未有的涨价潮正在以AI需求为圆心向全链条传导。

3.2.1 DRAM/NAND价格暴涨：现货价格半年涨300-500%

存储芯片是本轮涨价潮中最剧烈的环节。2026年Q1，常规DRAM合约价环比涨幅从最初预估的55-60%大幅上调至90-95%，创历史最大季度涨幅；NAND Flash合约价从预估的33-38%上调至55-60%。进入Q2，DRAM合约价继续上涨58-63%，NAND Flash上涨70-75%。

现货市场的涨幅更为惊人。DDR4 8Gb颗粒从3.2美元飙升至15美元，累计涨幅达369%；DDR4 16Gb模块一年内飙升约1,800%，创历史最大涨幅；DDR5内存条半年涨幅超过300%；32GB DDR5套装从2025年中约100-200美元飙升至350-600美元以上。

本轮存储涨价的核心驱动并非传统周期性供需失衡，而是“产能结构性转移”——AI服务器DRAM用量是传统服务器的8-10倍，全球约66%的DRAM产能已被AI服务器占用。更关键的是，三星、SK海力士、美光三大原厂将70%-80%的先进产能转向高利润的HBM（High Bandwidth Memory，高带宽内存）及DDR5产品，HBM芯片生产存在“1:3产能折损率”——每生产1GB HBM，消耗相当于3GB DDR的晶圆产能。

HBM成为最紧缺的环节。SK海力士2026年HBM产能已全部售罄，美光2026年所有HBM订单接近全部售出，三星HBM4产量亦已售罄；现在签约HBM的客户，交付窗口已排至2027年。SK海力士股价2026年年内上涨约250%，市值突破1.12万亿美元，成为韩国首家万亿市值公司之一。

3.2.2 光模块升级：800G/1.6T需求爆发，但800G已现过剩30-40%信号

光模块是AI数据中心内部互联的“神经网络”。全球AI专用光收发器模块市场预计从2025年的165亿美元飙升至2026年的260亿美元，同比增长超过57%。800G已成为绝对主流，2026年出货量预计达3,800万只；1.6T则从2025年的200万只激增至1,400万只。

中际旭创、新易盛、Coherent三家占据全球高端市场主要份额，订单排产分别至2027年Q2、2028年和2028年及以后。Coherent CEO Jim Anderson在2026年5月财报电话会上明确表示：“订单再次出现阶跃式增长，积压订单推至创纪录水平。客户排期现已延伸至2028年，长期协议甚至延伸到本十年末。”

然而，产能过剩的信号已经在800G领域显现。全球800G光模块产能约3,500-4,000万只，实际需求仅2,400-3,350万只，过剩率约30%-40%。价格战已经开始，800G单价从年初约3,500美元降至3,000美元左右，毛利率从40%以上降至30%左右。这一分化格局揭示了产业链的结构性特征：高端产品（1.6T）仍然紧缺，但已普及产品（800G）已开始面临供需平衡的拐点。

3.2.3 AI服务器全产业链涨价：从PCB（+40%）到液冷（+22%）到电子特气（+160%）

AI服务器整机制造所涉及的配套产业链，同样经历了全面的价格上行。

PCB（Printed Circuit Board，印刷电路板） 市场从2025年的400亿元跃升至2026年的900亿元以上，单台AI服务器PCB价值量达普通服务器的近10倍。上游材料全线涨价：建滔积层板2026年内四次涨价，累计涨幅超40%；电子布涨幅超80%；高端电子布供应缺口约40%。

液冷散热系统 正从“可选配置”变为“必选项”。NVIDIA H200 GPU单卡TDP（Thermal Design Power，热设计功耗）达700W，GB200 NVL72单机架功率达600kW，超过20kW必须采用液冷。数据中心液冷市场2025年55.2亿美元，2026年预计67.7亿美元，2031年达187.9亿美元，CAGR为22.65%。微软已于2025年2月宣布所有新服务器部署强制要求直触芯片液冷。

半导体材料 走出了十年难得的大涨行情。硅片涨价40%以上，光刻胶涨价15-25%，靶材涨价60-70%，电子特气涨幅达130-160%，稀有特种气体涨幅直接翻倍。2026年Q1全球半导体设备出货金额达365.5亿美元，同比增长14%，创历史最高单季纪录。

以下表格汇总了AI半导体全产业链各环节的价格涨幅与供需状态：

产业链环节	代表产品/指标	2026年价格涨幅	订单能见度	泡沫信号
存储芯片（DRAM）	合约价（Q1环比）	+90-95%	2026全年售罄	渠道现回调信号
存储芯片（NAND）	合约价（Q2环比）	+70-75%	2026全部售罄	新增产能2027年释放
存储芯片（HBM）	年度合约价	+18-20%	交付排至2027年	三大厂积极扩产
光模块（800G）	单价	下跌至3,000美元	排至2027-2028年	产能过剩30-40%
光模块（1.6T）	单价	维持高位	排至2028年	供需缺口30%+
晶圆代工（CoWoS）	封装报价	+15-20%	设备订单至2027年	产能缓解需至2027年
PCB	高端产品	+40%（单月）	至2027年	原材料持续上行
液冷散热	系统整体	CAGR 22.65%	至2026-2027年	未明显显现
AI服务器电源	单机价值量	+32%	至2026-2027年	未明显显现
半导体材料（电子特气）	特种气体	+130-160%	长期紧缺	国产替代窗口

图3-2 AI半导体产业链价格涨幅全景（2026年）




图3-2 AI半导体产业链价格涨幅全景

上图为产业链涨价提供了直观的量化全景。存储芯片以90-1,800%的涨幅居于所有环节之首，电子特气（130-160%）和功率芯片（85%）紧随其后。值得注意的是，不同环节的涨价逻辑存在本质差异：存储芯片的涨价主要由”产能结构性转移”驱动（产能从通用DRAM转向HBM），光模块800G的价格下跌则反映了技术迭代中的产能过剩，而半导体材料和配套组件的涨价更多由成本推动（原材料、能源、物流成本上升）。这种差异化驱动意味着，当AI需求增速放缓时，不同环节受到的冲击程度将大相径庭——存储芯片由于扩产周期长达18-24个月，价格粘性可能更强；而光模块由于技术迭代快、进入门槛低，价格调整可能更为剧烈。

3.3 泡沫信号：高估值与订单能见度

半导体产业链的繁荣数据背后，三个结构性泡沫信号值得高度关注：估值分化中的泡沫风险、订单能见度与新产能释放之间的时间错配，以及自研芯片对现有格局的长期威胁。

3.3.1 前瞻市盈率分析：NVDA 23x相对合理，AVGO 41x存在泡沫风险

从估值角度看，四大半导体巨头呈现出显著的分化格局。NVIDIA Forward P/E约23倍，不仅低于半导体行业中位数28.5倍，更远低于AMD的32倍和Broadcom的41倍。基于GuruFocus的分析，NVIDIA当前股价约183美元，比其估算公允价值305美元低40%，被评为“可能的估值陷阱”——即市场持续低估其增长潜力。TSMC的24倍Forward P/E在四家公司中最具估值吸引力，66%的毛利率和520-560亿美元的CAPEX计划为其提供了坚实的业绩可见度。

Broadcom的38-41倍Forward P/E则是泡沫风险最集中的标的。这一估值水平隐含了市场对其FY2027 AI收入超1,000亿美元、FY2028近1,900亿美元的目标给予了充分信任。然而，Deutsche Bank的预测已高出公司自身指引25%，任何执行上的偏差都可能导致剧烈的重定价。FY2026 Q2财报发布后股价因指引未上调而下跌14%的事件，已充分展示了这种估值脆弱性。

NVIDIA的熊市情景（约25%概率）提供了有用的风险锚定：若AI CAPEX周期在2027年见顶，定制芯片占据50%以上推理市场，毛利率压缩至55-58%，Forward P/E降至15-18倍，股价可能跌至105-162美元区间（从当前水平下跌9-41%）。值得注意的是，即便在这一熊市情景下，NVIDIA的营收仍预测为约3,000亿美元（较当前增长约39%），股价下跌完全由估值压缩驱动——这印证了成长股估值的基本数学：市场定价的不是绝对增长水平，而是增速能否维持。

3.3.2 订单排产排至2027-2028年，但新产能2026H2开始释放

当前半导体产业链的订单能见度提供了强有力的短期支撑。NVIDIA的1,190亿美元供应承诺覆盖至2031年，Broadcom的730亿美元AI积压订单预计在未来18个月内交付，TSMC的3nm/2nm产能排满至2027年，光模块龙头企业的订单延伸至2028年及以后。这种深度绑定的长期协议（Long-Term Agreement, LTA）在短期内确实降低了收入波动的风险。

然而，订单能见度与新产能释放之间存在微妙的时间错配。三星计划2026年HBM产能翻倍，SK海力士将产能提升80%，新产能将于2026年下半年陆续投产。TSMC将CoWoS产能从2024年底的每月3.5万片扩至2026年底的13万片（近4倍增长）。存储芯片的扩产周期为18-24个月，2026年的新增产能主要来自2024-2025年的CAPEX决策。这意味着，当前订单排产所反映的需求旺盛，可能尚未充分计入2026H2开始释放的新增供给。

Northland Capital和Barclays的分析均指向2027年中至2028年初为供需平衡的关键拐点窗口。当新增产能集中释放而CAPEX增速开始放缓时，当前支撑高估值的“供给紧张叙事”可能面临逆转。手握库存的下游中间商可能在价格拐点时面临损失，部分渠道市场DDR4/DDR5现货价格已出现下调信号。

3.3.3 自研芯片（Google TPU、Amazon Trainium）对NVIDIA的长期威胁

定制ASIC对NVIDIA构成的竞争威胁，是当前半导体格局中最具结构性的长期风险。NVIDIA在数据中心AI加速器市场的份额（按出货量）已从2022年的约95%下降至2026年的约62-66%。按收入计算，NVIDIA仍占约55-60%，但下降趋势已确立。

推理市场（Inference Market）是定制芯片渗透最快的领域。推理占GPU小时消耗的比例已从40%升至60%以上，而推理工作负载对硬件的要求低于训练，更容易被自研芯片替代。Google TPU v5、Amazon Trainium2、Microsoft Maia等自研芯片正在改善，已用于30-40%的推理工作负载。Marvell已与Google谈判开发新的AI推理芯片，显示超大规模客户正在主动分散供应商风险。

Broadcom虽然以70%的份额主导着定制AI加速器市场，但Google等客户也在寻求Marvell等替代供应商以降低成本和集中度风险。更深远的变化来自中国：中国AI芯片国产化率从0升至41%（2026年），华为目标2026年AI芯片收入120亿美元。国产AI芯片出货量达165万张，英伟达在华份额从95%跌至55%。

这一趋势的影响是多维度的。对NVIDIA而言，定制芯片的崛起意味着其通用GPU（Graphics Processing Unit，图形处理器）模式将面临持续的市场份额侵蚀，尤其在推理市场。对Broadcom和Marvell而言，它们既是NVIDIA的竞争对手（定制ASIC替代通用GPU），也是受益者（承接超大规模客户的定制芯片订单）。对TSMC而言，无论芯片由谁设计，只要采用先进制程，最终都要到台积电的晶圆厂生产——这使得TSMC在产业链中的“收费站”地位相对最为稳固。

综合判断，AI半导体行业正处于史上最大投资周期的顶峰。短期（12个月）内，订单积压和产能锁定提供了高度的收入能见度，“泡沫破裂”概率较低。但中期（2-3年）来看，超大规模CAPEX增速终将放缓（Barclays预测从2026年的60-88%降至2027年的35-40%），定制芯片竞争将加剧，而当前估值（尤其Broadcom的41倍Forward P/E）已计入大量乐观预期。NVIDIA和TSMC的估值相对合理，风险收益比可控；Broadcom和Marvell则要求更高的执行完美度来支撑其溢价估值。当CAPEX同比增速在2027-2028年见顶回落时，半导体板块可能面临30-50%的估值压缩——这并不意味着AI技术价值的消亡，而是对过度杠杆和过高预期的理性回归。

4. AI公司商业模式：财务真相揭幕

4.1 SpaceX/xAI：丑媳妇见公婆的第一个财报

2026年6月12日，SpaceX以“\$SPCX”为代码登陆纳斯达克，估值1.75万亿美元，计划募资750亿美元——这不仅是历史上规模最大的IPO，更是AI公司商业模式首次接受公开市场检验的标志性时刻。当Elon Musk将xAI以全股票交易并入SpaceX时，外界普遍认为这是一次巧妙的资本运作：一家亏损严重的AI初创公司通过绑定全球最有价值的未上市企业来规避独立上市的财务审查。然而，SEC的S-1注册声明撕开了这层面纱，让xAI的真实财务状况第一次暴露在公众投资者的显微镜下。

S-1文件揭示的数据令人震惊。2025年全年，合并后的SpaceX实体实现总营收186.7亿美元，同比增长33%，但GAAP净亏损高达49.4亿美元——而在2024年，公司尚能实现7.91亿美元的净利润。更令人警醒的是2026年第一季度的数据：仅一个季度内，净亏损就达到42.8亿美元，几乎追平2025全年的亏损规模。截至2026年3月，公司累计赤字已达413亿美元。

xAI分部是这一切亏损的源头。2025年全年，xAI（含X广告业务）实现营收32亿美元，但运营亏损高达63.55亿美元，亏损/收入比达到1.99:1。进入2026年后，情况不仅没有改善，反而急剧恶化：Q1营收仅为8.18亿美元，运营亏损却攀升至24.7亿美元，亏损/收入比恶化至3.02:1。年化计算，xAI的亏损率将接近100亿美元，而营收仅约33亿美元——运营利润率达到惊人的-302%。

指标	FY 2024	FY 2025	Q1 2026	Q1年化率
xAI部门营收	\$26.2亿	\$32亿	\$8.18亿	~\$32.7亿
xAI运营亏损	\$15.6亿	\$63.5亿	\$24.7亿	~\$98.8亿
xAI运营利润率	-60%	-200%	-302%	-302%
SpaceX合并净亏损	+\$7.91亿	-\$49.4亿	-\$42.8亿	-
AI CAPEX	-	\$127亿	\$77亿	~\$308亿
Starlink运营利润	-	\$44.2亿	\$11.9亿	-

表1：SpaceX/xAI关键财务指标（2024-Q1 2026）

这张表格的核心信息可以总结为一句话：xAI的亏损正在以远超收入增长的速度加速扩大。2024年xAI每收入1美元亏损0.60美元，2025年每收入1美元亏损2美元，到2026年Q1每收入1美元亏损3美元。这种趋势并非简单的“投资期”可以解释——如果亏损/收入比在持续恶化，那么问题就不是时间能否治愈，而是商业模式本身是否存在结构性缺陷。2025年平均季度亏损约为16亿美元，而Q1 2026单季亏损跳升至24.7亿，增幅超过50%。收入年化后基本持平（2025年32亿 vs Q1年化32.7亿），但亏损年化后从63.5亿飙升至98.8亿。

与此同时，Starlink成为整个合并实体中唯一真正盈利的部门。2025年Starlink实现营收113.9亿美元，运营利润44.23亿美元，运营利润率达39%，调整后EBITDA利润率更高达63%。Q1 2026 Starlink继续贡献11.9亿美元的运营利润。S-1文件所揭示的最赤裸的真相就是：如果不合并xAI，SpaceX原本是一家年盈利约80亿美元的健康企业；合并之后，它变成了一家年亏损近50亿美元、累计赤字超过400亿美元的财务黑洞。

SpaceX/xAI的IPO之所以成为“丑媳妇见公婆”的第一个真实案例，其意义远超单一公司层面。在上市之前，xAI作为私有公司可以凭借Elon Musk的个人光环和“AI改变人类未来”的叙事持续融资，累计完成427亿美元的股权融资。但IPO意味着季度财报、投资者电话会议、分析师模型——每一个季度的亏损都必须被量化、被比较、被定价。xAI的CAPEX同样在加速：2025年全年AI相关资本支出为127亿美元，Q1 2026单季即达77亿美元，年化后超过300亿美元，占总CAPEX的76%。这种资本密集度在科技史上几乎没有先例。

第一个post-IPO财报（Q2 2026）将是市场检验的关键时刻。如果Q2的亏损/收入比继续维持在3:1以上，市场将被迫回答一个根本性问题：AI公司的商业模式是否真的成立？xAI为OpenAI、Anthropic等其他计划上市的AI公司提供了一个悲观的模板——当财务披露不可避免时，市场是否愿意为每收入1美元就亏损3美元的业务支付90倍以上的收入倍数？

4.2 OpenAI：收入增长但亏损扩大

OpenAI是另一家即将面临同样考验的AI巨头。2026年5月，OpenAI年化收入（ARR）达到约250亿美元，从2025年6月的100亿美元年化收入到2026年3月的250亿美元，17个月内增长超过150%，这一速度在软件行业历史上前所未见。但与此同时，亏损规模也在同步扩大。OpenAI内部预计2026年non-GAAP运营亏损约140亿美元，但这只是冰山一角——Q1 2026实际运营亏损已达69.5亿美元，年化后接近280亿美元；计入股票薪酬后，2026全年GAAP净亏损预计将落在250-260亿美元区间，是广为引用的140亿美元数字的近两倍。

与xAI的对比揭示了两种不同但都令人不安的亏损模式。xAI的亏损/收入比更高（Q1为3.02:1），但OpenAI的绝对亏损规模更大。OpenAI Q1 2026运营利润率为-122%，虽略好于xAI的-302%，但这主要是因为OpenAI的收入基数更大（57亿美元 vs xAI的8.18亿美元），而非成本控制能力更强。更深层的问题在于OpenAI的毛利率正在下滑：从2024年的40%降至2025年的33%，远低于内部46%的目标。这是一种与传统SaaS规模经济截然相反的“反规模经济”效应——每增加一美元收入，公司在扣除直接成本后的剩余部分反而在减少。

训练成本的飙升是OpenAI独有的结构性压力。根据内部预测，OpenAI到2030年的年训练成本将达到1250亿美元，是Anthropic同期预测（约300亿美元）的四倍以上。OpenAI已承诺向CoreWeave支付总计224亿美元的云计算合同，并与SoftBank、Oracle合作推进5000亿美元的Stargate项目。这些基础设施承诺形成了巨大的固定成本基础，即使收入增长符合预期，折旧和摊销也将长期压制利润率。OpenAI于2026年5月22日向SEC秘密提交S-1文件，目标估值8500亿至1万亿美元，但当投资者看到Q1亏损近70亿美元的财报时，这个估值将面临严峻考验。

OpenAI的故事本质上与xAI相似：收入增长极快，但成本增长更快。两者的区别在于，OpenAI没有Starlink这样的盈利部门来补贴亏损，它依赖的是持续的外部融资——截至2026年，Microsoft持有约27%的股权（稀释后），累计投资约130亿美元。以250亿美元的年化亏损率计算，OpenAI的现金储备仅能支撑有限几年的跑道。

4.3 Anthropic：被政府列为供应链风险

在AI公司的财务版图中，Anthropic一度被视为“好学生”。2026年4月，其ARR突破300亿美元，已超过OpenAI的250亿美元；5月ARR进一步攀升至约470亿美元。更令人瞩目的是，Anthropic预计在2026年Q2实现营收109亿美元、有望首次录得单季度营业利润约5.59亿美元（基于市场预测，Q2财报尚未发布），有望成为AI模型行业内首家实现营业利润盈利的企业。其训练成本仅为OpenAI的四分之一，拥有超过1000家年支出100万美元以上的企业客户，财富10强中有8家是Claude用户。

然而，2026年上半年Anthropic遭遇的监管风暴为其IPO前景蒙上了浓重阴影。事件始于2026年1月9日，国防部长Pete Hegseth发布备忘录，要求所有国防部AI合同纳入”任何合法用途”条款。Anthropic拒绝了这一要求，坚持保留两项保障：禁止在无人监督的情况下将Claude用于自主武器系统，以及禁止大规模国内监控美国公民。谈判于2月破裂。3月5日，国防部正式将Anthropic列为”供应链风险”——这一标签此前仅用于华为、中兴等外国关联技术供应商，针对美国AI公司的使用尚属首次。

财务影响是直接的。Anthropic正在谈判的国防部合同价值高达2亿美元，是总额8亿美元的代理式AI合同的一部分。更深远的影响在于企业客户的合规焦虑：当一家AI供应商被五角大楼标记为”供应链风险”时，其政府关联客户和承包商伙伴将面临继续使用该产品的合规压力。法律文件描述2026年的收入影响将达到”数十亿美元”。

事态在6月12日进一步升级——就在Anthropic向SEC提交IPO申请后的第11天。当天美国商务部发布出口管制指令，要求暂停向任何外国公民（包括在美国的Anthropic外籍员工）提供Fable 5和Mythos 5模型的访问权限。由于无法实时区分用户国籍，Anthropic被迫在全球范围内禁用这两款其最先进的模型——而此时距离Fable 5公开发布仅三天。出口管制此前主要针对AI硬件，直接针对商业AI模型本身的部署尚属首次，标志着华盛顿对前沿AI模型的监管进入了一个全新阶段。Anthropic公开声明称这一决定基于”误解”，并指出被引用的所谓”越狱”技术在OpenAI的GPT-5.5等其他模型中同样存在。

Anthropic于6月1日向SEC秘密提交IPO申请，目标10月上市。但供应链风险标签和出口管制的双重打击令其前景充满不确定性。联邦法院于3月26日发布了初步禁令，暂停供应链风险指定的执行，但结构性问题远未解决。对于一家计划以9000亿美元以上估值上市的公司而言，被全球最大军事力量列为不可信任供应商的风险，远比季度亏损更让机构投资者警惕。

4.4 AI公司共同的盈利困境

SpaceX/xAI的IPO财报撕开的不只是xAI一家的财务真相，它暴露的是整个AI行业面临的共同困境。当AI-native公司的财务数据被放在公开市场标准下审视时，一个结构性问题浮出水面：它们的单位经济学与传统软件公司根本不同。

指标	OpenAI	Anthropic	xAI (SpaceX)	传统SaaS中位数	AI-Native平均
2026 ARR	\$250亿	\$300-470亿	~\$33亿	-	-
2026预计运营亏损	\$250-260亿(GAAP)	Q2首次盈利\$5.59亿	~\$99亿(年化)	+15-25%利润率	-
毛利率	~33%	~38-70%	未披露	78-85%	~52%
推理成本占收入	>20%	15-20%	>30%(估)	<2%	18-25%
收入倍数(估值/ARR)	34-40x	20-32x	50x+(含SpaceX)	4-8x	12-20x
IPO计划	2026 Q4	2026年10月	2026年6月	-	-

表2：头部AI公司盈利指标对比（2026年）

这张表格的核心启示在于毛利率差距。AI-native公司的平均毛利率约为52%，虽比2024年的41%有所改善，但仍远低于传统SaaS的78-85%。OpenAI的毛利率仅为33%，这意味着每收入100美元就有67美元被直接成本吞

噬。相比之下，成熟SaaS公司的直接成本通常只占收入的15-22%。Cohere以70%的毛利率在AI公司中独树一帜，证明通过架构选择（更小更高效的模型、企业私有化部署）可以改善AI经济，但这是少数例外。

毛利率低下的根源在于推理成本。对于AI-native产品而言，推理消耗占收入的18-25%，而传统SaaS不到2%。更棘手的是，与传统软件每增加一个用户边际成本趋近于零不同，AI公司的边际成本随着使用量增加而上升——每多一个查询就意味着更多的GPU算力消耗。2026年AI推理成本已占企业AI预算的85%，而2023年训练成本还占60%。Goldman Sachs预测2026-2030年间token消费将增长24倍，而每token成本虽然两年内下降了280倍，但总支出却增加了320%，因为Agentic工作流程消耗的token量是传统交互的10-20倍。这是一个悖论：技术效率的提升被需求的增长完全吞噬。

AI公司与云厂商的关系进一步复杂化了盈利前景。表面上看，云厂商是AI公司的算力供应商，但实际上双方形成了深度的相互依赖甚至“循环融资”关系。Microsoft投资OpenAI约130亿美元，同时OpenAI每年向Microsoft支付约60亿美元的收入分成和云计算费用。Google向Anthropic承诺400亿美元投资（含100亿现金+300亿计算额度），Amazon与Anthropic签署了超过1000亿美元的十年基础设施协议。这种交织的关系意味着AI公司的成本结构中有一大块流向了它们的战略合作伙伴——而这些合作伙伴同时还是它们的股东。当xAI的S-1文件显示其2025年127亿美元、Q1 2026年77亿美元的AI CAPEX大部分流向基础设施提供商时，投资者不得不追问：这些资本支出的回报率在哪里？

当SpaceX/xAI的S-1文件第一次将这些数字公之于众时，市场看到了一个令人不安的真相：在AI这个被视为下一个万亿级机会的行业中，头部玩家的商业模式尚未被验证。xAI以3.02:1的亏损/收入比登陆公开市场，OpenAI以-122%的季度运营利润率准备IPO，Anthropic虽率先实现盈利却被政府列入黑名单。三者之中，没有一家展现出投资者习以为常的软件公司盈利路径。

SpaceX/xAI的IPO因此不仅是一次上市事件，它是整个AI行业商业模式的第一次真正“压力测试”。xAI的亏损/收入比3.02:1且仍在恶化，这预示着当OpenAI、Anthropic等公司陆续披露财报时，市场可能面临一波估值重估。丑媳妇终究要见公婆——问题是，公婆是否准备好接受这个尚不具备盈利能力的“新娘”。

4.5 AGI奇点：被忽视的黑天鹅

在AI产业链的所有风险因子中，几乎没有任何一份卖方研报将“AGI递归自我改进”纳入基础情景分析。这一omissions并非无关紧要——如果人工智能系统能够以反馈循环的方式持续优化自身的推理效率，当前建立在“算力需求永远增长”假设之上的全部投资叙事，从hyperscaler的万亿美元CAPEX到NVIDIA远期估值中隐含的多年高增长预期，都将面临根本性重估。本节将论证：递归自我改进不仅是理论可能，其雏形已经显现；而推理成本的指数级下降，可能是这一黑天鹅事件最先露出的獠牙。

4.5.1 递归自我改进的潜在路径

当前AI系统展现出的自我改进能力，已远超“渐进式优化”的范畴。OpenAI的o3和o4-mini系列模型能够编写代码来优化自身的推理过程——这意味着模型不仅可以解决问题，还可以重构解决问题的方式。更具标志性的是DeepSeek-R1的“aha moment”：在纯强化学习训练过程中，模型自发地发展出链式思维（chain-of-thought）、自我验证（self-verification）和反思（reflection）能力，开始主动重新审视和修正自己的推理链条，而这些行为从未在训练数据中被显式示范。这种涌现性的自我修正能力，标志着AI系统首次跨入了“元认知”的门槛——它不仅知道答案，还知道自己在思考。

递归自我改进一旦启动，其首要优化目标极有可能指向推理效率本身。这一推断的逻辑链条异常清晰：对任何AI系统而言，更少的算力消耗意味着更快的响应时间、更低的运行成本和更大的可部署范围。换言之，“优化自己的推理效率”是递归改进循环中最自然、最有价值的第一站。而当一个系统能够持续以指数速度降低自身的算力需求时，Jevons 悖论——通常效率提升会刺激需求增长——可能会遭遇前所未有的反转。

4.5.2 推理成本正在指数级下降

推理成本的下降速度已经超越了摩尔定律的历史轨迹。根据Epoch AI及Andreessen Horowitz的分析，自2021年GPT-3发布以来，达到固定能力水平的LLM推理成本每年下降约10倍。2021年11月花费\$60完成的百万token推理任务，到2025年8月仅需约\$0.06——四年间实现了1000倍的成本压缩。这一降幅由硬件迭代（H100/H200的能效比提升）、模型量化（FP8/INT4精度降低计算需求）、软件优化（Flash Attention、推测性解码）和开源竞争四重力量共同驱动。

OpenAI自身的定价策略为这一趋势提供了最直接的注脚。o3模型在2025年4月发布时定价为\$10/\$40每百万输入/输出token，仅两个月后即大幅下调80%至\$2/\$8，并引入缓存输入折扣（重复内容仅需\$0.50/百万token）和Batch API 50%折扣。o4-mini进一步将门槛拉低至\$1.10/\$4.40。而GPT-5.4虽然每token定价（\$2.50/\$15.00）高于前代GPT-5.2（\$1.75/\$14.00），却在复杂任务上减少了47%的token消耗，使得实际任务成本不升反降。

架构层面的创新同样在加速成本坍塌。DeepSeek-R1采用的MoE（Mixture-of-Experts）架构在671B总参数中每次仅激活37B参数，配合MLA（Multi-head Latent Attention）显著压缩KV缓存，再加上FP8原生量化——三重优化叠加，使得一个与GPT-4级别相当的模型可以以极低成本部署。FP8量化在H100上的实测数据显示，相比BF16格式，推理吞吐量提升1.4-1.8倍，KV缓存内存占用减少50%，单位token成本从\$1.19/百万降至\$0.71/百万。

模型蒸馏则是另一条被低估的效率路径。DeepSeek将R1的推理能力蒸馏至1.5B到70B参数的小模型系列中，其中R1-Distill-Qwen-7B在数学推理任务上相对基础模型提升54.36%，R1-Distill-Qwen-1.5B更是实现了178.74%的跃升。蒸馏后的70B Llama模型在AIME 2024数学竞赛基准上达到70.0分，在GPQA Diamond研究生级别问答上获得65.2分，双双超越Claude-3.5-Sonnet等闭源大模型。这意味着，7B-70B规模的小模型已可在特定任务上达到3-5倍更大模型的性能水平。

表4-5：主要模型推理成本演进（2025-2026，含2026年旗舰）

模型	发布时间	输入价格 \$/1M	输出价格 \$/1M	关键效率特征	相对前代 / 定位
o3 (首发价)	2025.04	\$10.00	\$40.00	推理模型，长 CoT 生成	基准
o3 (降价后)	2025.06	\$2.00	\$8.00	同上，+缓存/ Batch 折扣	-80%
o4-mini	2025.04	\$1.10	\$4.40	轻量推理，速度优化	-45% (vs o3 降价后)
GPT-5.2	2025.12	\$1.75	\$14.00	400K 上下文窗口	+75% 输入/输出 (vs o4-mini)
GPT-5.4	2026.03	\$2.50	\$15.00	复杂任务 token 效率 +47%	任务成本实际下降
DeepSeek-R1	2025.01	~\$0.55	~\$2.19	MoE 671B/37B 激活，MLA+FP8	约 4-18x 低于同级
R1-Distill-Qwen-7B	2025.01	~\$0.10	~\$0.10	7B 蒸馏，推理专用	百倍级成本优势
GPT-5.5	2026	\$5.00	\$30.00	旗舰，1.05M 上下文，缓存输入 \$0.50	旗舰定价 (Batch \$2.50/\$15)
Claude Opus 4.8	2026	\$5.00	\$25.00	1M 上下文，自适应思考	当前旗舰 Opus
Claude Fable 5	2026.06	\$10.00	\$50.00	最强公开模型，1M 上下文	顶级旗舰

注：Claude Mythos 5 能力与定价同 Fable 5（输入 \$10 / 输出 \$50 每百万 token），仅通过 Project Glasswing 受邀使用，未公开发售；OpenAI、Anthropic 旗舰均另有 Batch、缓存输入等折扣，上表为标准价。价格核对时点为 2026 年 6 月。

上表的数据揭示了一个被市场系统性低估的趋势：推理成本的下降不仅发生在“每代模型”之间，更发生在同一代模型的生命周期之内——o3在两个月内降价80%，GPT-5.4以更高的单token定价实现了更低的任务成本。这种“双重下降”（定价下调+效率上调）意味着，即使模型代际更新速度放缓，成本曲线仍将以陡峭斜率持续下探。DeepSeek-R1及其蒸馏系列的出现，更是将这一趋势推向了极致：一个7B参数的蒸馏模型，在数学和编码任务上可媲美数百B参数的前沿模型，而成本差距高达两个数量级。当效率提升的速度持续超越需求增长的速度时，Jevons�论的历史经验——瓦特蒸汽机提高效率反而增加了煤炭总消耗——可能不再适用。与此同时，2026 年的前沿旗舰（GPT-5.5、Claude Opus 4.8、Claude Fable 5）仍维持每百万 token \$5-\$10 的输入定价：成本曲线在低端坍塌，前沿定价却另立高位，顶级能力的溢价与蒸馏模型的成本坍塌长期并存。

4.5.3 Jevons�论的反转：效率提升可能导致需求崩溃

Jevons�论的传统表述是：资源使用效率的提升降低了单位成本，进而刺激更多应用场景的涌现，最终导致总资源消耗不降反升。微软CEO Satya Nadella在DeepSeek-R1发布后引用这一悖论，暗示更高效AI将“skyrocketing”算力需求。这一论点在2025年的分析师报告中几乎成为共识。

然而，这一推理存在一个致命的盲区：Jevons�论的前提是“效率提升由外部力量驱动”（如更好的蒸汽机设计），而非“资源消耗者自身驱动”。如果AI系统自身成为效率提升的源泉——通过递归自我改进持续压缩自身的算力需求——那么历史先例可能完全失效。做一个思想实验：如果灯泡能够自己让自己发光效率提高

1000倍，电力需求不会增加，因为照明的“服务量”（流明-小时）受物理空间和使用时间约束，存在明确上限。AI推理同样面临应用场景的上限约束——并非所有认知任务都值得自动化。

当前推理已占总算力消耗的60%以上，且这一比例仍在快速攀升——NVIDIA内部数据显示，推理占GPU小时消耗的比例从2025年初的约40%跃升至60%+。Gartner预测推理工作负载将从2023年的33%增长至2029年的65%以上。推理市场预计从2025年的\$106B增长至2030年的\$255B。这些预测的全部隐含假设是：单位token成本下降会带来token使用量的超比例增长——即Jevons悖论成立。

但如果AGI递归自我改进使推理效率在某一时间点实现100倍以上的跃升，总需求可能非但不增加，反而减少。原因在于：更高效的模型意味着同样的任务需要更少的GPU小时、更小的数据中心和更低的电力消耗。当前推理模型（如DeepSeek R1）已消耗150倍于传统推理的算力——如果AI自身能找到方法将这种“暴力推理”压缩到仅需当前1%的资源，同时保持或提升输出质量，那么即使应用场景扩展10倍，总算力需求仍将下降90%。这不是科幻推演，而是已经在以温和版本发生的现实：GPT-5.4在复杂任务上比GPT-5.2减少47%的token消耗，仅差一个数量级就将触及Jevons反转的临界点。

4.5.4 对产业链的影响

递归自我改进驱动的效率飞跃，对AI产业链各环节的冲击将呈现高度不对称的格局。

半导体公司——尤其是NVIDIA——面临的是断崖式风险。该公司数据中心业务的增长叙事建立在“推理需求持续爆发”的假设之上：Blackwell和Vera Rubin累计订单需求已达1万亿美元（至2027年底），而推理需求的爆发是上调预测的核心驱动力。如果推理需求因AI自我优化而意外收缩，这些已锁定的订单可能面临客户违约或延期风险。更重要的是，GPU的“性能过剩”将迅速侵蚀定价权——当一个小模型可以在消费级硬件上运行前沿级推理时，\$3万一块的H100的必要性将遭受根本性质疑。

云厂商则可能是意外的受益者。推理效率提升意味着同样的GPU集群可以服务更多客户，单位硬件的营收产出（revenue per GPU）反而可能上升。微软、谷歌和AWS的核心竞争力在于客户关系和分销网络，而非算力本身。如果AI推理变得极度廉价，最大的受益者将是能够以最低边际成本大规模分销AI服务的平台——正如云计算降低了IT成本却扩大了AWS的市值一样。

时间线判断：基于当前推理成本每年下降10倍的速度，以及模型自我优化能力的初步显现，第一波由AI自身驱动的效率飞跃预计可能在2028-2030年间出现。这一时间窗口与供需分析中识别的“供需平衡拐点”（2027年底至2028年初）形成危险的重叠——如果效率提升恰好发生在供给大规模释放之时，算力市场的价格崩溃将比任何单一因素的冲击都更为剧烈。

4.5.5 情景分析

综合上述分析，我们为AGI递归自我改进对算力需求的影响构建三个情景：

情景A：Jevons悖论成立（基准情景，概率50%）

推理成本继续以每年5-10倍的速度下降，但token使用量和应用场景以同等或更快的速度扩张。推理市场从2025年的\$106B增长至2030年的\$255B，总算力需求持续上升。NVIDIA保持增长但增速从2026财年的60%逐步放缓至2028财年的22%。这是当前市场一致预期已经定价的情景。

情景B：AGI递归优化（黑天鹅情景，概率20%）

2028-2030年间，AI系统实现递归自我改进，推理效率在相对短时间内跃升100倍以上。推理占总算力消耗60%+的结构性特征 使得总算力需求出现意外下降——应用场景的扩展不足以抵消单位任务算力消耗的坍塌。NVIDIA数据中心收入面临断崖式风险，可能出现连续季度的负增长。云厂商因单位硬件产出提升而相对抗跌。这一情景的概率虽低，但其冲击的烈度和市场未定价的程度，使其成为最大的尾部风险。

情景C：混合情景（概率30%）

训练需求继续增长——前沿模型的竞争确保了每代新模型的训练投入仍在2-4倍扩张 ——但推理需求在AGI出现后因自我优化而趋于平稳甚至下降。产业链出现结构性分化：训练芯片（如NVIDIA B200/Vera Rubin）需求保持强劲，而推理专用芯片和存量GPU面临利用率下滑。Hyperscaler CAPEX 的构成从“推理扩容”转向“训练竞赛”，总投资规模可能低于当前预测（Barclays预测2027-2028年capex可能超出共识\$2250亿以上）。

值得警惕的是，当前几乎没有主流卖方模型将情景B纳入估值框架。Barclays的万亿美元capex预测、瑞银的“数据中心毫无降温迹象”、以及Marvell的\$3490亿加速计算TAM估计，全部建立在需求端线性或指数增长的基础上。如果AGI递归自我改进这一黑天鹅展翅，当前市场上所有基于DCF或相对估值的AI半导体目标价，都可能在一夜之间失去锚定。

5. 算力租赁经济学：不挣钱的中间商

AI公司与算力租赁商的关系，表面上是供需合作，实际上是共同陷入困境——场面轰轰烈烈，账本却不甚好看。2026年，算力租赁市场正经历前所未有的疯狂涨价：H100（NVIDIA Hopper架构高端数据中心GPU）租赁价格在半年内飙升近40%，H200的月租金突破6万元人民币，而全球GPU算力资源的交付排期已延至2027年。在这股涨价狂潮中，云厂商和算力租赁商看似坐收渔利，但揭开财报的面纱，真相远比表面复杂。AWS的Bedrock服务确实实现了约55%的EBIT利润率，Azure和Google Cloud的AI业务却因IaaS（Infrastructure as a Service，基础设施即服务）模式占比过高而利润率受压。至于被NVIDIA力捧为“AI基础设施新范式”的CoreWeave，其财务报表更像是一份风险提示书——收入翻倍的同时净亏损扩大135%，债务股本比高达5.2，内部人士三个月内抛售26.5亿美元股票而零买入。

5.1 算力租赁市场疯狂涨价

5.1.1 H100租赁价格半年涨40%，H200月租金达6-6.6万元

算力租赁市场的价格走势打破了半导体行业“新款上市、旧款降价”的常规逻辑。H100一年期租赁合约价格从2025年10月的1.70美元/GPU/小时一路涨至2026年3月的2.35美元/GPU/小时，短短五个月涨幅近40%。现货市场更为夸张，Lambda报价已上浮至4美元/小时以上，是两年前的两倍。SiliconData的H100超大规模指数在2026年4月底跳涨至7.49美元/小时。

更反常的是，新一代Blackwell架构的B200芯片上市后，旧款H200的价格不降反升。H200现货价格从4.96美元/小时涨至6.40美元/小时，涨幅29%，而B200的on-demand价格仅为5.68美元/小时，出现了明显的“价格倒挂”。H200月租金在中国市场达6.0-6.6万元人民币，环比上涨25-30%。

GPU型号	2024年低点	2025年10月	2026年3月	涨幅（自2024低点）	交付排期
H100	~\$1.70/h	\$1.70/h	\$2.35/h	+38%	36-52周
H200	—	\$4.96/h	\$6.40/h	+29%（自2025）	40+周
B200	—	—	\$5.68/h	基线	预订至2027H2
A800（中国）	—	—	2.5元/卡时	基线	3-4周
昇腾910B（国产）	—	—	1.8元/卡时	较A800低28%	2-3周

表5-1：主流GPU租赁价格趋势与交付排期（2024-2026年）

表5-1揭示了一个核心矛盾：尽管NVIDIA新一代Blackwell架构已出货，但市场对“旧款”Hopper架构芯片的需求不减反增。这一现象的背后是三重因素的叠加：第一，B200的实际可用产能极为有限，已被预订至2027年下半年；第二，H200在推理场景中的性价比经过充分验证，企业客户不愿冒险迁移至新架构；第三，HBM（High Bandwidth Memory，高带宽存储）产能的全面售罄限制了所有高端GPU的供给——SK Hynix、三星、美光三家制造商已售完全部2026年HBM3e产能。

中国市场同样经历了剧烈的价格上涨。2026年一季度国内算力租赁市场规模达680亿元，同比增长62%，全年预计突破2600亿元。英伟达高端卡型（H100、B200）涨幅达30%-40%，中端卡型（A10、A800）涨幅15%-20%，而国产芯片适配套餐（昇腾910B/920）涨幅仅10%-15%。国产GPU租赁价格（1.8元/卡时）较英伟达A100（2.5元/卡时）低28%，这一价格优势正在推动国产替代加速。

5.1.2 全球GPU算力资源基本售罄，交付排期至2027年

供给端的约束是价格上涨的根本推手。截至2026年初，北美数据中心空置率降至1.6%的历史最低水平，新加坡空置率仅1.4%，马来西亚柔佛空置率仅1.1%。全球数据中心空置率因AI需求降至2.8%。所有2026年8-9月前计划上线的算力已被全部预订。

更深层的瓶颈在于半导体供应链。HBM需求年增长80-100%，而供给仅增长50-60%。TSMC的CoWoS（Chip-on-Wafer-on-Substrate，晶圆上芯片封装）先进封装产能完全分配至至少2027年中期，NVIDIA估计占据TSMC CoWoS产能的约60%至2027年。TSMC计划2026年将CoWoS产能扩至每月9万片晶圆，2027年扩至13万片，但全面缓解不太可能早于2027年底。

Token需求的爆发式增长进一步加剧了供需失衡。从2025年10月的600万/分钟增至2026年3月的约150亿/分钟——5个月内增长2500倍。中国日均token调用量从2024年初的1000亿增长到2026年3月的140万亿，两年增长超1000倍。推理已占有AI算力的约三分之二。NVIDIA预测推理算力需求将比训练需求高出1000倍。

5.1.3 云厂商同步涨价：AWS、Azure、Google Cloud AI服务涨价15-34%

GPU租赁市场的涨价潮迅速传导至云厂商的AI服务定价。AWS、Azure和Google Cloud在2025至2026年间将AI相关服务价格上调15%-34%。云厂商的涨价策略呈现出明显的差异化：AWS通过Bedrock（Token as a Service模式）将成本压力有效传导至终端客户，同时保持自身利润率；Azure和Google Cloud则因IaaS模式占比过高，在涨价幅度上更为谨慎，以免客户转向其他供应商。

云厂商自身也在承受CAPEX的巨大压力。2026年美国超大规模云厂商AI资本支出总额预计达约7000亿美元，其中Amazon约2000亿美元、Alphabet 1750-1850亿美元、Microsoft 约1900亿美元、Meta 1150-1350亿美元、Oracle 500亿美元。Microsoft FY2025投入882亿美元capex，AI收入仅179亿美元，连capex的零头都未能覆盖。

5.2 云厂商AI服务的利润真相

5.2.1 AWS Bedrock（TaaS模式）EBIT利润率约55%

云厂商AI服务的利润表现呈现出显著的分化，核心变量在于商业模式的选择。SemiAnalysis的Tokenomics模型揭示了一个关键发现：AWS的AI收入占总收入比例从2024年第一季度的2%提升至2026年第一季度的10%。

Bedrock——AWS的TaaS（Token as a Service，Token即服务）平台——已稳步增长至AWS AI总收入的37%（2025年第一季度仅为9%），成为一个55亿美元运行率的业务。

Bedrock的EBIT利润率约55%（2026年第一季度）。这一数字仅贡献AWS总收入的4%，却贡献了AWS年度毛利润增长的30%。TaaS模式的高利润率源于其“中间商溢价”：AWS以批量折扣价从Anthropic等模型提供商处采购token，再以更高价格转售给企业客户，赚取差价的同时承担技术集成和运维服务的角色。

AWS 2026年第一季度收入376亿美元（同比增长28%），运营利润141.6亿美元，运营利润率37.6%。AI服务年化收入超过150亿美元，Bedrock客户支出环比增长170%，处理的token超过之前所有年份总和。芯片业务（Trainium+Graviton）年收入运行率超200亿美元，Trainium承诺金额超2250亿美元。

5.2.2 Azure和GCP因IaaS占比高利润率受压

与AWS的TaaS策略形成对比，Azure和Google Cloud的AI业务仍以IaaS模式（租赁GPU）为主，AI IaaS占比仍超过80%。这种结构性差异直接影响了利润率表现：AWS的EBIT利润率环比增加213个基点，而Azure和GCP的利润率则承受压力。

Azure 2026年第一季度增长40%，其中约16个百分点来自AI服务，AI业务年化收入运行率超370亿美元，Microsoft 365 Copilot付费席位突破2000万。然而，Microsoft Cloud毛利率从69%降至66%，表明AI服务的高增长伴随着利润稀释。Google Cloud 2026年第一季度收入增长63%至200亿美元，营业利润率从17.8%扩大至32.9%，但Google的利润率计算方式未将DeepMind的训练成本计入云业务成本，存在会计处理的差异。

指标	AWS	Azure	Google Cloud
2026年Q1收入	\$37.6B (+28%)	~\$29.3B (+40%)	\$20.0B (+63%)
运营利润率	37.6%	~40%	32.9%
AI收入运行率	>\$15B	>\$37B	未单独披露
AI占总收入比	~10%	~27%	~36%
主导商业模式	TaaS (Bedrock 37%)	IaaS (80%+)	IaaS (80%+)
AI EBIT利润率趋势	上升 (+213bps)	承压	上升（但未计入DeepMind成本）

表5-2：三大云厂商AI服务利润对比（2026年Q1）

表5-2揭示了一个反直觉的结论：AI收入占比最高的云厂商（Google Cloud，36%）并不一定拥有最健康的AI利润结构。AWS通过TaaS模式将AI收入的利润质量最大化，而Azure和GCP的IaaS主导模式则更像“搬运工”——出租GPU硬件赚取差价，利润率远低于转售token的TaaS模式。这一差异意味着，当GPU租赁价格下行周期来临时，AWS的AI利润将比Azure和GCP更具韧性。

5.2.3 整体AI服务业务仍无法覆盖CAPEX投入

尽管AWS Bedrock的利润率令人印象深刻，但将所有云厂商的AI服务收入加总后，与CAPEX投入相比仍显得杯水车薪。JPMorgan估计，AI行业需要每年6500亿美元的收入才能在2030年前实现10%的投资回报，而当前AI直接收入仅约300-600亿美元，存在约10-20倍的缺口。

Bank of America的计算显示，云厂商的capex已消耗运营现金流的94%。当capex超过运营现金流时，公司必须借债或发股。五大云厂商2026年已通过债务融资1210亿美元（同比增长4.3倍）来维持资本支出。这种模式可以持续，直到债权人或股东失去信心。

Google CEO Sundar Pichai表示“如果我们能满足需求，云收入会更高”，暗示供给约束而非需求不足是当前的主要瓶颈。但这并不能消除投资回报率（ROI）的根本疑虑——如果企业客户最终以远低于预期的速度采用AI服务，当前数千亿美元的capex投入将面临严重的产能过剩风险。


5.3 CoreWeave：煤矿中的金丝雀

5.3.1 财务数据：Q1 营收21亿（+112%），净亏损7.4亿，债务249亿

CoreWeave是算力租赁行业最具代表性的公司，也是AI基础设施泡沫最集中的微观样本。2026年第一季度，CoreWeave营收20.8亿美元，同比增长112%，环比增长32%。收入积压（Revenue Backlog）从259亿美元增至994亿美元，同比增长284%。表面上，这是一家高速增长公司的理想画像。

但利润表讲述了一个截然不同的故事。GAAP净亏损7.40亿美元，较去年同期3.15亿美元扩大135%。调整后EBITDA为11.57亿美元，利润率56%（同比下降6个百分点）。调整后营业收入仅2100万美元，利润率骤降至1%，而去年同期为1.63亿美元（利润率17%）。利息支出5.36亿美元，同比增长103%，几乎吞噬了一半的调整后EBITDA。

资产负债表更令人警醒。债务总额约250亿美元，股东权益仅48亿美元，债务股本比高达5.2。CoreWeave的实际总债务约为S-1文件中披露数字的3倍以上——公司利用会计准则将大量债务隐藏在表外。2026年有42亿美元债务到期，需再融资或偿还。DDTL 1.0贷款额度23亿美元浮动利率约15%，2028年3月到期；DDTL 2.0贷款额度76亿美元平均利率约11%，2026年1月开始偿还。New Constructs在其IPO前报告中指出，CoreWeave按2024年的烧钱速度仅能维持约2.5个月，“几乎在上市前就具备了僵尸股票的特征”。



CoreWeave财务指标恶化趋势

图5-1：CoreWeave收入增长但亏损同步扩大（左）；关键财务健康指标全面恶化（右）

图5-1的左侧面板展示了CoreWeave收入与亏损的同步攀升——从2025年第一季度的9.82亿美元收入增长至2026年第一季度的20.78亿美元，同期净亏损从3.15亿美元扩大至7.40亿美元。右侧面板则揭示了关键财务指标的全面恶化：调整后EBITDA利润率从62%降至56%，调整后营业利润率从17%暴跌至1%，债务股本比从3.5攀升至5.2。这四项指标的同步恶化构成了一个典型的“高增长陷阱”——收入增长完全依赖资本投入，而资本投入的回报效率正在急剧下降。

5.3.2 客户集中度风险：从“微软依赖”（71%）转向“Meta+OpenAI依赖”（65%）

CoreWeave的客户集中度问题并未因多元化努力而得到实质性改善，只是风险的主角发生了变化。2024年全年，微软占CoreWeave收入的62%，前两大客户合计77%。到2025年第二季度，微软占比一度升至71%。尽管此后公司通过签下Meta（142亿美元合同）和扩展OpenAI（总合同224亿美元）来分散风险，但在扩展后的994亿美元积压订单中，Meta占40.1%，OpenAI占25.5%，合计近65%。

客户集中度从“微软依赖”转变为“Meta+OpenAI依赖”，本质上并未降低风险。D.A. Davidson分析师Gil Luria认为，微软不太可能续约CoreWeave合同，而OpenAI的财务承诺也存在风险——“你必须相信OpenAI会取得不可思议的成功，以至于能够偿还所有排在其前面的债务”。Luria更直言不讳地表示，CoreWeave在5年时间窗口内最可能的结局是破产——“要么其现有客户届时能够依赖自有基础设施，要么日益捉襟见肘的CoreWeave将不再能够借到钱”。

客户集中度的风险具有自我强化的特性。如果Meta或OpenAI因自身财务困难而削减算力订单，CoreWeave的收入将立即遭受重创，进而影响其偿债能力和再融资能力，最终可能触发债务违约。而CoreWeave的商业模式本质上缺乏护城河——GPU租赁是商品化服务，面临超大规模云厂商的直接竞争，而Microsoft、Google和Amazon等最大客户同时是其最大的竞争对手。

5.3.3 内幕人士3个月抛售26.5亿美元股票，零买入的警示信号

在所有警示信号中，内部人士的交易行为可能是最不容忽视的。CoreWeave内部人士在过去3个月内卖出约26.5亿美元股票，涉及85笔交易，而买入记录为零。Magnetar Capital（持股10%的股东）在2026年4-5月大规模减持，仅5月1日就卖出128万股套现1.54亿美元。CEO Michael Intrator持续定期出售约30.7万股/次，单次套现约3000-3700万美元。首席战略官Brian Venturo也在持续大量卖出。

内部人士的大规模抛售通常被市场解读为对公司当前估值缺乏信心的信号。当管理层选择套现而非增持时，外部投资者理应保持警惕。CoreWeave的GF Score仅18/100（满分100），财务强度评分3/10，盈利能力评分2/10，这一量化评分系统进一步印证了公司的基本面脆弱性。

著名做空者Jim Chanos（以预见安然破产闻名）对新云公司的GPU担保债务发出严重警告。他指出，CoreWeave和Fluidstack各有约100亿美元GPU担保债务，Lambda有5亿美元，Crusoe有4.25亿美元。如果这些高杠杆公司出现违约，作为抵押品的GPU价值快速折旧可能导致债权人遭受重大损失，甚至触发连锁反应。2026年1月，四名美国参议员（包括Elizabeth Warren）致信金融稳定监督委员会（FSOC），要求对AI相关债务风险启动正式金融稳定调查，警告“AI公司无法快速增加收入以偿还巨额债务可能引发金融危机”。

CoreWeave还面临至少5家律师事务所发起的证券欺诈集体诉讼，指控其夸大满足客户需求的能力并低估对单一第三方数据中心供应商（Core Scientific）的依赖风险。诉讼案号Masaitis v. CoreWeave, Inc., No. 26-cv-00355 (D.N.J.)目前正在审理中。

综合来看，CoreWeave的财务状况是整个AI基础设施泡沫的微观缩影——高负债、高资本支出、低利润、客户集中、依赖再融资。如果CoreWeave在IPO后不到两年的时间内就面临如此严重的财务压力，那么整个行业数以千亿计的capex投入是否能够在未来3-5年内产生合理的投资回报，答案正变得越来越不确定。正如做空大师Jim Chanos所言：“如果（盈利）没有改变，这些债务将面临违约。”

6. 供需平衡拐点：泡沫破裂的触发器

6.1 供给端：产能释放时间表

AI算力供给端的最大瓶颈——台积电CoWoS先进封装——正在经历一轮史无前例的产能扩张。摩根士丹利与汇丰的联合研究显示，台积电CoWoS产能在2022至2027年期间的复合年增长率超过80%，月产能从2024年底的3.5万片攀升至2026年底的12万至13万片。然而，这种看似激进的扩产计划仍无法填补需求缺口：2026年CoWoS缺口预计达25%至30%，且这一紧张状态将延续至2027年下半年。英伟达已预订台积电2026年80万至85万片晶圆产能，占据超50%份额，其他客户（AMD、博通、云厂商自研芯片）只能在剩余产能中展开激烈争夺。

NVIDIA的产品迭代节奏是供给释放的另一关键变量。Blackwell B200已于2025年下半年进入规模化出货，而基于台积电3nm工艺的Vera Rubin架构（3360亿晶体管、288GB HBM4、50 PFLOPS算力）预计于2026年下半年进入全面量产，2027年第一季度实现大规模交付。这意味着2026年第二至第三季度将是新一代GPU产能爬坡的关键窗口。值得注意的是，NVIDIA在GTC 2026上确认Blackwell与Vera Rubin累计订单需求已达1万亿美元（至2027年底），是此前预测的两倍——这一数字既印证了需求的强劲，也暗示供给端短期内难以跟上。

中国市场则呈现出一条独立的供给曲线。IDC 2025年度报告显示，中国AI加速卡市场总出货量约400万张，其中国产厂商（华为昇腾、寒武纪、阿里平头哥等）合计出货165万张，市场份额跃升至41%。华为以约81.2万片的出货量占据国产芯片半壁江山，阿里平头哥出货约26.5万片，百度昆仑芯与寒武纪各约11.6万片。这一结构性转变意味着，到2026年，中国AI算力市场的供给来源将呈现“双轨制”：国际市场由NVIDIA主导，国内市场则由国产芯片支撑一个相对独立的生态系统。

HBM高带宽内存作为第二大供给瓶颈，同样处于产能爬坡期。SK海力士2026年全年HBM产能已全部预定，2026年第一季度全球HBM3e芯片出货量1200万颗，缺口仍达35%。美光与三星的新产能预计2026年底开始贡献实质性增量，但HBM供应的全面缓解可能要推迟至2027年底至2028年初。综合来看，供给端的最优情景是2027年下半年开始出现实质性缓解，2028年初供需趋于平衡。

6.2 需求端：训练与推理的结构裂变

如果说供给端的故事是“产能追赶”，需求端的故事则是“结构裂变”。AI工作负载正经历一场从训练向推理的深刻迁移。NVIDIA内部数据显示，推理已占GPU小时消耗的超60%，而这一数字在2025年初仅约40%。Gartner的预测更为激进：推理工作负载占比将从2023年的33%攀升至2029年的65%以上，推理市场规模从2025年的1060亿美元增长至2030年的2550亿美元。

这种结构变化对供需平衡的影响是双刃剑。一方面，推理需求的爆发性增长支撑了持续的投资热情——每一次ChatGPT查询、每一个AI生成图像、每一轮智能体（Agentic AI）自主决策，都在消耗算力。但另一方面，推理对硬件效率的要求远高于训练：DeepSeek R1等推理模型消耗的算力是传统推理的150倍，一次完整的推理调用可能产生20倍于传统模型的token输出。这使得推理需求的增长并非线性，而是带有显著的“阶跃”特征。

更具颠覆性的是效率优化对总需求的潜在压缩。DeepSeek V3/R1以不到600万美元的训练成本实现了对标GPT-4o的性能（需注意：该数字仅为最终训练运行的GPU租用估算，不含前期研发、失败实验与基础设施投

入，实际总投入要高出数量级以上），引发市场对算力需求可能被高估的恐慌。微软CEO萨提亚·纳德拉援引杰文斯悖论（Jevons Paradox）回应称，效率提升将降低单位成本，进而刺激更多应用采纳，最终扩大总需求。但这一辩论远未结束：经济学人的分析指出，杰文斯悖论是经济史上罕见的例外而非常态，反弹效应通常不足以完全抵消效率提升。如果AI的采用弹性低于预期，效率优化可能直接转化为算力需求的净减少。

企业层面的投资回报率（ROI）数据则更为严峻。MIT 2025年《生成式AI商业现状》报告——基于对52位企业高管的深度访谈、153位领导者的问卷调查以及300个公开AI部署案例的分析——发现尽管企业在生成式AI上投入了300亿至400亿美元，95%的组织未能看到可测量的P&L回报（该结论因样本范围与“可测量回报”的界定方式而受到一定质疑，宜作为方向性信号而非精确比例）。仅有5%的企业级AI系统成功进入生产阶段并产生显著价值。更值得警惕的是，虽然超过80%的企业已试点ChatGPT或Copilot等工具，但这些工具主要提升个人生产力，而非企业层面的财务绩效。这种“高采用率、低转化率”的悖论意味着，当前支撑AI Capex需求叙事的核心逻辑——企业愿意为AI基础设施支付溢价——可能比你我想象的更加脆弱。

6.3 Capex 增速拐点：泡沫破裂的关键信号

理解AI泡沫何时破裂，关键看一个量：Capex 的同比增速有没有见顶回落。

核心判断：要盯的不是增速的正负——只要还在扩张，同比增速一直为正——而是增速本身的方向。增速还在往上走（一年比一年涨得更快），是泡沫膨胀期；增速见顶、开始往下走，哪怕 Capex 绝对值还在创新高，泡沫也进入了危险区。关键认知在于：即使 Capex 绝对值仍在增长，只要增速不及此前，市场就会开始重估。

一个形象的类比：想象一辆高速行驶的汽车。速度仍在增加，但驾驶员已经松了油门。乘客未必能立刻感知到减速，但加速度的消失预示着速度终将下降。对于成长股而言，市场定价的不是Capex的绝对水平，而是Capex的“超预期”程度。当增速从80%降至38%，尽管Capex总额从7200亿美元跃升至1.16万亿美元，但“增速溢价”已经消退——这对估值40倍以上、股价中已经隐含了多年60%+增长预期的AI龙头来说，同样致命。

高盛在其2025年9月的研究报告中明确指出了这一机制：Capex 增速见顶回落这一拐点，终将对估值形成考验。然而，判断拐点时机极具挑战，因为云厂商持续上调Capex指引，使得市场一致预期始终滞后于实际支出。这种“预期追赶现实”的动态，恰恰解释了为何泡沫可以在增速见顶之前持续膨胀。

下表呈现了2024至2028年的完整Capex轨迹与增速拐点分析：


表1：Capex 增速轨迹与拐点分析（2024-2028E）

年份	Capex总额（十亿美元）	同比增速	增速方向	阶段判定	市场含义
2024	~\$235	+44%	—	复苏期	疫情后AI投资启动
2025	~\$400	+70%	加速上行	加速期	ChatGPT效应，投资涌入
2026E	\$660-\$750	+60%~+88%	仍在加速上行	加速末期	最后的疯狂，产能锁定
2027E	~\$1,160	+35%~+40%	见顶回落	⚠️ 拐点区	增速见顶回落，估值承压
2028E	~\$1,300+	+12%~+25%	持续回落	减速期	增速常态化，估值回归

数据来源：Barclays、高盛、Moody’s、Marvell综合预测

这一数据揭示了一个关键的时序结构：2025至2026年是Capex的”加速期”（增速仍在上行），增速从44%攀升至60%-88%的峰值区间。2026年很可能是本轮Capex周期的增速顶点——尽管绝对值继续攀升至6600亿至7500亿美元，但增速的上行动能开始耗尽。2027年是决定性的转折年：Barclays预测 hyperscaler Capex将达到1.16万亿美元，但同比增速骤降至35%-40% 。增速仍远高于零，但已经明确见顶回落。2028年，Marvell预测数据中心Capex将突破万亿美元大关，但增速进一步收窄至10%-25% 。

需要诚实标注这一框架的边界：增速见顶本身是个偏滞后的确认信号——等你看到它，股价往往已经走了一程；而且这条减速路径基本是卖方共识、已被部分定价。同时”2026年增速仍在加速”这一判断依赖于取60-88%区间的上界，若采用点估计（2025年约70%、2026年中值约74%），增速其实已接近走平，拐点甚至可能早于基准情景出现。因此本报告给出的拐点时点（2027年Q2-Q3）应理解为概率中枢而非精确预言；真正可操作、也更接近因果的领先信号是 RPO 增速、自由现金流转负、以及有没有云厂率先砍 Capex 指引（见6.4 与第 10 章）。



AI Capex增长轨迹与增速拐点

图1: AI Capex增长轨迹与增速拐点 (2024-2028E) —— 柱状图显示Capex总额持续攀升, 但红线所示的同比增长率在2026年达到约80%的峰值后断崖式下降。绿色区域为增速上行期, 红色区域为增速回落期。2027年是增速见顶回落的关键拐点, 即使Capex绝对值仍在增长, 市场也将对“增速不及预期”做出负面反应。

需要特别强调这一机制的心理学维度。投资者购买英伟达、AMD和AI基础设施股票时, 定价模型中嵌入的不是当前Capex水平, 而是对未来数年Capex复合增速的预期。当市场一致预期2026年增速为80%、2027年为50%时, 若实际数据呈现80%和38%, 即使后者绝对值更高, “预期差”仍会引发估值压缩。这正是成长股估值的残酷数学: PE倍数中隐含的永续增长假设, 对增速能否维持异常敏感。

Barclays的预测提供了另一个值得深思的角度: 该行认为2027年和2028年云厂商Capex可能比市场共识高出2250亿美元以上。这一判断的逻辑基于OpenAI和Anthropic的财务数据推算——如果头部AI公司需要持续扩张算力以维持技术领先, 云厂商的Capex增长将被迫跟进。然而, 即便Barclays的乐观预测成真, 2027年Capex/经营现金流比率将攀升至92%, 2028年更达到97%。这意味着云厂商将在两年内耗尽几乎全部经营现金流用于AI投资, 必须依赖债务和股权融资维持扩张——一条显然不可持续的路径。

6.4 触发条件: 五重压力矩阵

增速见顶回落是泡沫破裂的内在机制, 但触发这一机制的具体催化剂可以来自多个维度。我们识别出五个关键触发条件, 构成一个“五重压力矩阵”。

触发条件一: 某家大型云厂商宣布削减AI CAPEX。 这一信号已经出现。Microsoft在2026年6月被TD Cowen渠道调查确认取消了约200MW的数据中心租约, CFO在财报会议上承认“存在过剩容量”, CEO纳德拉更预期2027-2028年将出现“过度建设”。Microsoft是2023-2024年最活跃的数据中心租户, 已允许超过1GW的意向书到期, 并暂停了威斯康星州原支持OpenAI的数据中心建设。如果Microsoft——OpenAI的最大投资方和算力提供方——都开始收缩, 其他云厂商跟进只是时间问题。高盛的观察也印证了这一趋势: 英伟达营收增速已连续第七个季度放缓, 从峰值的265%降至2025年第四季度的56%; 2026年第二季度的营收指引环比增速从20%进一步降至11%。

触发条件二: AI应用公司大规模破产或财务暴雷。 这一条件正在酝酿中。SpaceX/xAI的财务状况可能就是第一个明确信号——埃隆·马斯克旗下的xAI已在孟菲斯数据中心投入数十亿美元, 但其Grok聊天机器人远未实现商业规模的收入。更广泛的背景是: 2026年底至2027年初, “投入-收入剪刀差”将走到临界点——四大云厂2026年AI资本开支超7000亿美元, 同比涨幅超60%, 但对应的AI业务收入增速仅35%, 自由现金流已暴跌70%至90%。当折旧和利息费用在2026年下半年集中爆发, 部分AI应用公司将难以维系。

触发条件三: 利率大幅上升或经济衰退。 摩根大通预测美联储2027年可能重启加息, 10年期美债收益率只要持续站稳4.35%以上, 高估值科技股将直接面临杀估值压力。云厂商Capex/经营现金流比率在2028年将达到97%, 接近消耗全部经营现金流, 需依赖债务和股权融资。如果融资环境恶化, 这一脆弱的资金链可能迅速收紧。

触发条件四 (新增): AI递归自我改进导致算力需求意外下降。 这是一个此前较少讨论但潜在影响巨大的风险场景。当前AI Capex预测的一个隐含假设是: 模型规模将持续扩大 (GPT-5、Claude-4等下一代模型需要2-4倍于前代的训练算力), 且智能体 (Agentic AI) 将创造全新的算力需求类别。但如果AI在2027年前后实现某种形式的递归自我改进 (recursive self-improvement) ——即AI系统能够以比人类更低的成本优化自身架构

——则对新增硬件算力的需求可能意外收缩。这一场景的概率较低（估计5%-10%），但其一旦发生，对当前万亿美元级Capex计划的冲击将是毁灭性的。

触发条件五（新增）：AI“核武器化”导致全球市场分裂。 随着中美科技脱钩加深，中国已限制磷化铟（InP）出口，导致AI数据中心光互连面临60个工作日的审批延迟。如果AI技术被进一步“核武器化”——即各国将先进的AI能力视为战略武器，实施严格的技术封锁和出口管制——全球AI算力市场可能分裂为两个或更多互不兼容的生态系统。这种分裂将同时影响供给端（供应链断裂）和需求端（跨国AI服务无法运营），对依赖全球化供应链的Capex计划构成系统性威胁。

这五个触发条件并非独立事件，而是可能相互强化的。例如，触发条件四（效率突破）可能加速触发条件二（AI公司财务困难），而触发条件五（地缘政治）可能同时放大触发条件一（Capex削减）和触发条件三（融资约束）。当三个或以上触发条件同时激活时，硬着陆的概率将显著上升。

6.5 最可能情景：2027-2029年”软着陆”

基于上述供给、需求与增速拐点的分析，我们构建了三情景概率框架：

表2：AI Capex周期情景分析矩阵

情景	概率	时间窗口	核心假设	Capex轨迹	市场影响
乐观情景：AGI加速	30%	2027-2028	AGI突破带来新一轮Capex加速，增速重新上行 20	27年增速维持50%+ 泡	沫继续膨胀，估值进一步扩张
⚠️ 最可能情景：RPO 缓冲下的软着陆 *	*55%** *	*2027-2029** *	*Capex增速有序放缓，增速见顶回落，但仍为正	2027年+35% ^{40%} ， 2028年+12% ^{25%** **}	估值压缩30%~50%，板块震荡但不崩盘**
极端情景：硬着陆	15%	2026底-2027	多重触发条件共振，增速可能转负 C	apex绝对值下降 板	块40%-60%修正，类似2000年

概率为作者基于当前信息的主观估计，仅供参考

最可能情景（55%概率）是2027-2029年的”软着陆”。这一情景的核心特征是：Capex 同比增速在2027年第二至第三季度正式见顶回落（首个增速环比下降的财报季），但增速仍保持正值——即Capex绝对值继续增长，只是增速从80%的峰值回落至35%-40%。市场对此的反应将是渐进式的估值压缩：AI龙头股的PE倍数从当前的40-50倍回落至25-30倍，股价回调幅度在30%-50%之间，但整体板块不出现灾难性崩盘。这一情景与 Goldman Sachs的Tracking Trillions分析、以及Oliver Wyman 2026年1月的评估方向一致：AI泡沫最可能的结果是30%-50%的估值修正，而非2000年式的彻底破裂。

关键时间窗口是2027年第二季度至第三季度。为什么是这一时点？三条独立的证据线在此交汇：第一，台积电CoWoS和HBM的产能释放将在2027年下半年开始实质性缓解供需缺口；第二，Barclays预测的Capex增速放缓从2027年开始显现（从60%+降至35%-40%）；第三，英伟达Vera Rubin架构的大规模量产将在2027年第一季度完成爬坡，届时GPU供给不再构成硬约束，云厂商的”恐慌性抢购”动机将减弱。当第一个大型云厂商在2027年中报中给出低于预期的Capex指引时，市场将对”增速溢价”进行重新定价。

乐观情景（30%概率）依赖于一个重大的技术突破——通用人工智能（AGI）或接近AGI的能力在2027年前后实现。如果OpenAI、Google DeepMind或Anthropic发布的能力飞跃足以证明，当前万亿级Capex投入将在未来3-5年内产生指数级回报，那么Capex增速可能重新上行。Agentic AI的爆发性增长也可能扮演类似角色——

如果智能体在2026-2027年成功渗透企业核心工作流，创造出一个全新的、规模堪比当前LLM推理的算力需求类别，当前的Capex水平将被证明是保守的。然而，即便在这一乐观情景下，部分股票仍可能因预期过满而经历阶段性回调。

极端情景（15%概率） 对应2000年式崩盘。触发条件是上述五个触发条件中的三个或以上同时激活：例如，Microsoft正式削减AI CAPEX（条件一）+ 头部AI应用公司大规模破产（条件二）+ 美联储意外加息（条件三）。这种多重共振可能在2026年底至2027年初引发板块性恐慌，导致AI相关股票在6-12个月内下跌40%-60%。市场上部分评估将硬着陆概率定在20%左右，而我们给出的15%略低，主要考虑到当前AI基础设施的需求基础——全球数据中心使用率仍高达97%，在建项目中77%已获预租——比2000年电信泡沫时期的“光纤过剩”要有更为坚实的基本面支撑。

需要密切监控的先行指标包括：英伟达季度营收环比增速（已从20%降至11%）；云厂商Capex/经营现金流比率（接近90%时风险升温）；数据中心空置率（从1.6%回升至5%以上时供给显著缓解）；H100云租赁价格（现货价已从峰值约8美元/小时回落至2.85-3.50美元/小时，而一年期合约价仍维持在2.35美元/小时高位——现货领先合约回落，是供给紧张缓解的早期信号）；以及台积电CoWoS产能利用率（从2025年8月的60%恢复至80%以上将标志着供给紧张缓解）。当这些指标中有三个以上同时发出警告信号时，软着陆的概率将下降，硬着陆的概率将上升。

无论哪种情景最终兑现，增速拐点的分析框架都指向同一个结论：2026年是Capex增速的顶点年份，2027年是拐点年份，2028年是“算力过剩”从预测变为现实的年份。对于投资者而言，关键不是在增速见顶回落时抛售，而是在增速仍在上行（即2026年）时，就已在组合中为即将到来的增速放缓预留安全边际。正如高盛所警示的：判断拐点时机仍具挑战，但拐点终将到来——而市场的历史反复证明，它总是来得比大多数人预期的更早。

7. 历史镜鉴：光纤泡沫与移动互联网的教训

技术史的一个核心悖论在于：基础设施泡沫的建造者很少成为最终价值的捕获者。19世纪英国铁路狂热的投资者输掉了资本，但英国获得了一个世纪的运输骨架；2000年电信泡沫烧掉了约2万亿美元，却为Google与Amazon的崛起铺平了道路；中国移动运营商的万亿级基建投入最终成就了腾讯的移动互联网帝国。当前AI基础设施投资急剧膨胀——2025年五大云厂商（Hyperscaler）资本支出预计达6,600亿至6,900亿美元——与这些历史泡沫呈现出惊人的结构性相似。本章通过系统比较三次技术基础设施泡沫的演进轨迹，论证一个核心命题：基建泡沫的破裂不是终点，而是价值从基础设施层向应用层大规模转移的开端。

7.1 2000年光纤泡沫：最像当前的历史参照

7.1.1 投资与收入缺口：当前18倍 vs 光纤泡沫约3倍

1996—2001年间，全球电信运营商以每天约4,000英里的速度铺设光纤电缆，总计铺设了足够环绕地球1,500圈的光纤。仅WorldCom一家公司的投入就高达5,000亿美元。然而到2001年，这些光纤中不到3%被实际“点亮”使用，其余97%成为“暗光纤”（dark fiber）。泡沫期间总损失估计达2万亿美元，WorldCom、Global Crossing等行业巨头相继破产。

从投资/收入缺口看，当前AI基建泡沫的严重程度远超光纤泡沫。后者的投资/收入比约为3:1。而当前，按Sequoia Capital合伙人David Cahn的测算，仅支撑现有GPU投资就需要终端用户产生约6,000亿美元年收入，而当前全球AI直接收入仅约1,000亿美元——同口径（需求缺口）约为6:1；若以单年CAPEX对窄口径AI直接收入计，则高达约28:1。无论采用哪种口径，失衡程度均不低于、甚至高于光纤泡沫。这一被称为“AI's \$600B Question”的缺口在2023年9月至2024年6月的9个月内从2,000亿美元扩大了三倍。Arxiv的一篇同行评审论文直接将AI数据中心泡沫风险与电信光纤过度建设相提并论：“如果数据中心基于GPU多年高利用率的假设进行融资，但芯片代际更替迅速……这与2000年代初期的电信光纤过度建设高度相似”。东南亚数据中心市场当前正在进行的370亿美元以上投资、6,068MW新产能，与光纤泡沫图景如出一辙。

7.1.2 泡沫破裂后97%光纤闲置，但成为互联网基础设施

Lux Capital的分析指出，2000年代泡沫时期铺设的“暗光纤”在债务减记后成为低成本宽带时代的基础设施基础，使YouTube、Facebook等数据密集型应用成为可能。带宽成本在四年内下降了约90%。风险投资家Josh Wolfe对此有精准概括：“YouTube之所以能够存在，完全是因为2000年代初期铺设了所有那些光纤电缆。”对AI基建投资者而言，这一历史暗示了一个令人不安的可能：当前hyperscaler的天量资本支出，最终可能以折旧减记和资产减值的方式，为未来AI应用公司的低成本算力使用subsidize。

但必须给“基建终将留下、价值转移到应用层”这一乐观类比一个最强反驳：光纤与铁路是寿命20-50年的物理资产，泡沫破裂后仍能在低价下被新应用反复利用；而AI算力的核心载体GPU通常3-5年即因代际更替而性能与能效双重过时（这正是上文Arxiv论文点名的风险）。一旦下一代芯片使单位算力成本大幅下降，今天天量采购的H100/H200可能不是“闲置后被重新点亮的暗光纤”，而是“迅速贬值的库存”。因此，“破裂后底层资产继续创造价值”的命题在硬件层要弱得多——真正能跨越周期留存的，更可能是数据中心的电力、土地、网络与冷却等长寿命部分，而非GPU本身。这是本报告历史类比中最大的不确定性来源。

7.1.3 幸存者：并非光纤公司，而是Google、Amazon等应用公司

泡沫破裂后的价值再分配方向清晰而残酷。光纤建设公司几乎全部消失，而利用廉价带宽构建应用的公司却成长为全球市值最高的企业。亚马逊在2000年股价暴跌90%后通过裁员和聚焦供应链效率重新启航，三年后首次实现盈利。谷歌凭借搜索广告模式脱颖而出，Facebook、Twitter等后来者更直接在泡沫冷却后的低估值环境中成长起来。硅谷风投TSVC创始合伙人夏淳对此总结道：“历史经验表明，基础设施泡沫破裂后的最大受益者往往是应用层公司，而非基础设施公司。”

7.2 移动互联网周期：基建烧完，腾讯笑纳

7.2.1 中国移动运营商万亿级基建投资，最终受益者是腾讯、阿里


2009—2015年间，中国移动、中国联通、中国电信三大运营商在3G/4G网络建设上投入了超过万亿元人民币的资本支出。然而，真正的价值捕获者是腾讯和阿里巴巴。2011年腾讯推出微信，从一个简单的即时通讯应用迅速演变为涵盖社交网络、移动支付、游戏、电商的“超级应用”。2011—2015年间，中国移动互联网用户基数从4亿增至7亿，智能手机价格降至1,000元人民币以下——正是这一庞大的、由运营商补贴的用户基础，让微信得以在极短时间内覆盖绝大多数中国网民。

投资界的分析将这一模式提炼为普适性规律：“历史经验表明，基础设施建设的最大受益者往往不是建造者，而是使用者。在铁路时代，尽管许多铁路公司破产，但铁路基础设施催生了现代物流体系，使美国制造业效率提升约25%。” Goldman Sachs首席股票研究官Jim Covello进一步指出，本轮AI周期中的价值转移可能更加极端：“在每一个周期中，半导体公司都在客户繁荣时蓬勃发展。但在当前AI周期中，半导体公司在客户之上所有人的经济代价上蓬勃发展——这是历史上前所未有的。” 这意味着，即使在基建期内，价值已经被上游半导体公司前置性地抽取，留给基建公司 and 应用公司的空间更加逼仄。

7.2.2 时间线：2009—2015年基建高峰期，2015—2020年应用爆发期

移动互联网周期的时序特征尤为值得注意。2009—2015年是基建高峰期，而2015—2020年则是应用爆发期——微信支付普及、抖音崛起、拼多多上市。这一“时滞”源于三个条件的成熟：基础设施覆盖率达到临界规模、终端设备成本降至大众水平、网络体验足以支撑商业化应用。

图表7-1的中间面板清晰展示了这一模式：中国移动运营商资本支出在2015年达到峰值后开始回落，而腾讯市值恰恰在这一拐点之后开始指数级上升。基础设施投资的边际回报率递减与应用层价值的边际回报率递增形成了经典的“剪刀差”。



图表7-1：三次技术基础设施泡沫的基建投资与应用层价值演进对比

数据来源：Telecom CAPEX数据综合行业报告；Tencent市值数据来自Bloomberg；AI CAPEX数据综合各公司财报指引及Northland Capital预测。注：2028—2030年数据为基于历史模式的推测（E）。

7.2.3 AI周期的时间压缩：基建期可能更短（2023—2028），应用爆发紧随其后

图表7-1的三个面板揭示了一个关键趋势：技术周期的整体时长正在压缩。光纤泡沫的完整周期约15年（1996—2010），移动互联网周期缩短至约10年（2009—2020），而当前AI周期的基建期可能仅有5—6年（2023—2028）。

Northland Capital Markets预测AI基础设施投资周期“处于第7局，将在2027年中放缓”，预计“电力和资本约束在2027年将恶化”，可能导致“两到三年”的暂停期，之后是“J型复苏”。时间压缩的原因有三：技术迭代速度加快，每一代技术的前代都成为“数字基础设施”的一部分；资本规模和流动性远胜历史——五大科技巨头的AAA级信用评级提供了光纤时代电信运营商所不具备的“减震器”；学习曲线效应——市场已从历史泡沫中吸取了教训，虽然这不意味着泡沫可以避免，但可能改变其破裂的形态。

7.3 铁路泡沫：更久远但本质相同的教训

7.3.1 1840年代英国铁路泡沫：股价暴跌85%，但90%现代英国铁路网源于泡沫期

1840年代的英国铁路狂热（Railway Mania）是人类历史上第一次大规模技术基础设施投机泡沫。巅峰时期，铁路投资占英国GDP的7%，占经济总投资的一半。仅1845年一年，议会就授权了约3,000英里铁路——相当于此前15年的总和。投资者包括查尔斯·达尔文（据称损失高达60%净资产）、约翰·斯图尔特·密尔和勃朗特姐妹。

1847年泡沫破裂，到1850年初铁路股票价格平均暴跌85%。然而，到1855年英国已拥有超过8,000英里运营铁路轨道。经济史学家的研究表明，英国现代铁路网络约90%的长度可追溯到泡沫年份规划或建造的线路。

表7-1 三次技术基础设施泡沫核心指标对比

对比维度	铁路泡沫（1840s）	光纤泡沫（1996—2001）	AI基建泡沫（2023—2028E）
峰值投资规模	占GDP 7%	电信业5,000亿美元	Hyperscaler CAPEX 6,600—6,900亿美元
融资方式	个人投资者举债认购	2,500亿美元垃圾债券	2025年发债1,210亿美元（5年均值4倍）
投资/收入缺口	铁路运营收入远不及预期	约3:1	约6:1（需求缺口口径）
峰值后价格跌幅	股价平均暴跌85%	纳斯达克跌78%，多家公司破产	尚未发生（预测估值压缩30—50%）
闲置/过剩产能	部分线路初期客流不足	85—97%光纤未点亮	AI直接收入仅覆盖CAPEX约4-7%
泡沫破裂后遗产	90%现代英国铁路网源于泡沫期	云计算/流媒体的基础设施基础	待观察：可能成为未来AI应用的底层算力
最终价值捕获者	运输公司、制造业	Google、Amazon、Facebook	预测：已有生态的平台型公司

表7-1的系统性比较揭示了一个跨越两个世纪的共同规律。AI基建泡沫的投资/收入缺口（需求缺口口径约6:1，若按单年CAPEX/窄口径AI收入计则高达约28:1）已不低于、甚至超过铁路泡沫和光纤泡沫，暗示当前泡沫的“膨胀度”可能处于历史极端水平。然而，与前两次泡沫不同的是，当前AI基建的主要资助者均为全球利润最高、现金流最充沛的企业，这一结构性差异可能改变泡沫破裂的形态——从2000年式的崩盘转变为2027—2029年的“缓慢修正”。

7.3.2 核心规律：基建泡沫破裂后，底层技术继续创造价值，价值从基建向应用转移

经济学家Carlota Perez在《技术革命与金融资本》中指出，每次技术革命都遵循“安装期”（installation phase，特征是投机狂热和泡沫破裂）和“部署期”（deployment phase，特征是生产力释放的“黄金时代”）的两阶段模式。AI当前正处于安装期的后期阶段。

泡沫和技术的价值是两个必须区分的问题。Foreign Affairs Forum的分析精确指出：“即使AI是一个‘生产性泡沫’，投资者仍可能遭受重大损失。泡沫再分配财富——从热情的股票持有者再分配给工人、承包商和未来基础设施的使用者。”历史规律的高度一致性令人警醒：铁路公司破产了，但铁路网留下了；电信公司破产了，但光纤网络留下了；中国移动运营商的万亿投资没有带来对应回报，但为腾讯 subsidized 了基础设施。AI数据中心公司——尤其是那些高度杠杆化的纯基建玩家——可能面临类似的命运。而价值捕获者的名单预计将再次出现在应用层：已经拥有用户基础、分发渠道和生态系统的平台型公司。正如夏淳所言：“基础设施真的必要吗？是的。但建造基础设施的人能赚到钱吗？历史说不。”

8. 宏观环境：特朗普周期与利率风暴

2026年，AI投资正身处宏观政策高度不确定性的“完美风暴”中心。特朗普第二任期的关税政策在法律与行政令之间反复横跳，美联储货币政策从鸽派转向鹰派的速度超出市场预期，美国财政赤字逼近历史高位。三家权威机构对美国经济衰退概率的预测已攀升至30%-49%区间，而德意志银行调查显示57%的机构投资者将“科技泡沫破裂”列为2026年最大风险。宏观环境正在从低利率、低波动、高流动性的“黄金三角”转向其反面——这对高度依赖远期现金流折现的高估值科技股而言，意味着系统性的估值承压。

8.1 特朗普政策的不确定性

8.1.1 关税政策反复50+次，半导体供应链持续承压

2026年2月20日，美国最高法院以6:3裁定特朗普政府援引《国际紧急经济权力法》（IEEPA）征收的大规模关税违法。这部分约占特朗普加征关税的75%，但依据《贸易扩展法》第232条款的钢铝、汽车及芯片关税不受影响；该裁决涉及未来十年约1.4万亿美元的预期财政收入。这一裁决本应标志关税战的政策拐点，但特朗普政府在裁决后数小时内即援引第122条款对全球商品重新加征10%关税（后提高至15%），并启动史上范围最广的301调查，准备在122条款7月到期后继续对各国征收差异化关税。

至此，特朗普第二任期内的关税政策反复变化已达50余次。2025年美国平均有效关税税率为7.7%，为1947年以来最高水平。根据纽约联储研究，关税成本绝大部分由美国人自己承担——2026年3月关税税率下，平均每个家庭面临约600美元新增成本，高盛研究显示约70%关税成本被转嫁至消费者。关税推升通胀的传导机制正在加速运转：核心PCE（个人消费支出价格指数）通胀率已连续4个月超过3%，远高于美联储2%的目标。

半导体行业成为关税战的直接靶心。2026年1月，《美国贸易扩展法》第232条对高性能AI半导体加征25%关税。英伟达H200芯片虽获准对华出口，但须满足50%配额、第三方验证、用途管控等严苛条件，且需缴纳25%关税。关税叠加出口管制形成的“双刃剑”效应正在重塑全球芯片贸易格局——既限制了中国获取先进芯片的渠道，也严重损害了美国半导体企业的收入基础。

8.1.2 对华芯片出口管制：NVIDIA在华份额从95%跌至55%

美国对华芯片出口管制自2022年《芯片与科学法案》启动以来持续加码，但2025-2026年达到了前所未有的密度。英伟达（NVIDIA）是中国AI芯片市场的最大受害者：据IDC数据，2025年中国AI加速卡市场总出货约400万张，英伟达出货约220万张，市场份额从制裁前的约95%暴跌至55%。Bernstein Research甚至预测，若出口管制进一步收紧，英伟达2026年在华份额可能降至8%。

这一急剧收缩对英伟达的财务影响不可小觑。中国曾是英伟达最大的区域市场之一，贡献了其数据中心收入的约20%-25%。以2025年中国AI芯片市场规模约300亿美元估算，英伟达在中国的收入损失可能在60亿-80亿美元区间。信息技术与创新基金会（ITIF）的研究指出，对华半导体出口管制减少了美国芯片制造商的收入，进而削弱了其研发投资能力和行业就业——这种“反噬效应”正在通过产业链逐级传导。

8.1.3 意外后果：加速中国AI芯片国产化，改变全球供需格局

出口管制的最大意外后果，是催化了中国AI芯片产业的跨越式崛起。2025年，中国国产厂商合计出货AI加速卡165万张，市场份额首次突破四成，达41%。华为以81.2万张出货量领跑国产阵营，占整体市场20%。华为

预计2026年AI芯片收入将达约120亿美元，同比增长至少60%，其Ascend 950PR芯片已于2026年3月量产。摩根士丹利预测，中国AI芯片市场2030年将达670亿美元，其中86%将由中国供应商供应。

从全球视角看，这意味着AI算力供给曲线可能比预期更快向右移动。中国芯片国产化不仅减少了英伟达和台积电的订单需求，还增加了全球算力供给总量。ITIF与Omdia的分析认为，全球半导体供应链正在加速“双轨化”——中美各自发展独立的EDA工具、芯片架构和软件栈，跨境技术审计和标准统一日益困难。对于评估AI泡沫的持续时间而言，这一结构性变化意味着供需平衡的拐点可能提前到来。

8.2 利率与债市风险

8.2.1 美联储2026年不降息预期：10年期美债收益率维持4.56%高位

2026年初，市场争论的焦点还是美联储年内将降息几次；到了6月，交易的重点已彻底切换为“加息多少基点”。6月5日非农就业数据大超预期（17.2万vs预期8.5万），加上通胀持续高企，强化了美联储结束货币宽松的政策立场。景顺固定收益高级投资组合经理预计，2026年美联储的基准情景是“不会降息，或者最多降息一次”，2年期美债收益率大概率维持在3.7%-4.2%区间。

截至2026年6月，10年期美债收益率为4.56%，1周内上涨2.01%，1个月内上涨2.24%，3个月内上涨2.93%。这一水平显著高于2008年金融危机后的历史均值（约2.5%），反映了持续高于目标的通胀预期、上升的期限溢价以及市场对财政供给的担忧。图8.1展示了特朗普周期内10年期美债收益率的波动轨迹以及各机构对美国经




图8.1 宏观风险综合仪表盘：美债收益率走势与衰退概率预测

利率上升对科技股估值的传导机制直接而猛烈。2022年美联储激进加息以对抗通胀，NASDAQ全年下跌32.5%，为2008年以来最差表现；S&P 500最低时下跌近27%。高估值科技股的定价逻辑本质上是远期现金流的折现——当折现率从3%升至4.56%，一家10年后才能实现稳定盈利的公司，其现值可能缩水30%-50%。

洛克菲勒国际董事长Ruchir Sharma在2026年初明确提出警告：“所有泡沫的破裂都源于同一因素：更高的利率。一旦美国经济通胀回升迫使美联储转向加息，当前由AI资本支出驱动的过度投资泡沫将面临终结。”这一判断与凯投宏观（Capital Economics）的预测高度一致——后者同样预测AI泡沫将在2026年因利率和通胀上升而破裂。

8.2.2 美国财政赤字2.2万亿美元，联邦债务逼近39万亿美元

推高长端收益率的另一关键变量是史无前例的财政扩张。华泰证券预测2026财年美国财政赤字规模可能达到2.2万亿美元，赤字率上升至7%，超过市场预期。截至2026年5月，美国联邦债务总额已逼近39万亿美元。2025年5月，穆迪将美国主权信用评级从Aaa下调至Aa1，美国历史上首次同时失去三大评级机构的最高评级。穆迪预计未来10年美国政府债务占GDP比重将升至134%。

财政赤字的货币化压力正在通过国债供给渠道传导至长端收益率。最高法院裁定总统无权征收IEEPA关税后，原本指望靠关税填补财政缺口的路径被堵死，面临约1,750亿美元的关税退款风险。一边是海量的国债供给，一边是海外央行持有意愿下降，供需失衡是美债遭抛售的最底层原因。景顺分析师指出，如果市场层面需要更高的收益率去应对美债供需失衡，就可能出现结构性的债务可持续性问题的。

8.2.3 57%机构将”科技泡沫破裂”列为2026年最大风险

德意志银行2025年12月客户调查显示，57%的受访者将科技泡沫破裂列为三大风险之首，创单一风险选择比例的历史新高。德银分析师Jim Reid表示从未见过单一风险如此领先于其他选项，并警告”今天的AI龙头企业规模更大，系统重要性更强，可以说比2008年的银行业更具系统重要性”。

这一警告并非危言耸听。超大规模云厂商2026年AI资本支出合计达7,200亿美元以上，大量资本支出依赖债务融资。当CAPEX（资本支出）已消耗运营现金流的94%（美国银行测算数据），利率上升将同时增加融资成本和压缩估值倍数，形成对科技股的双重挤压。

8.3 经济衰退概率

8.3.1 穆迪模型显示衰退概率48.6%

2026年3月，多家机构集中上调了美国经济衰退概率预测。穆迪分析公司模型显示未来12个月衰退概率已升至48.6%，接近”抛硬币”的水平；威尔明顿信托预计45%；安永-博智隆（EY-Parthenon）预计40%；高盛将其预测提高至30%；预测市场Polymarket显示2026年底前衰退概率飙升至41%。通常情况下，这一概率应在20%左右。

机构/指标	衰退概率	预测时间窗口	关键假设
穆迪分析（Moody’s Analytics）	48.6%	未来12个月	模型驱动：贸易政策冲击、高利率、消费者信心下滑
威尔明顿信托（Wilmington Trust）	45.0%	未来12个月	关税累积效应、企业投资放缓
安永-博智隆（EY-Parthenon）	40.0%	未来12个月	消费者支出减速、信贷条件收紧
Polymarket预测市场	41.0%	2026年底前	市场共识：油价、关税、AI泡沫综合风险
高盛（Goldman Sachs）	30.0%	未来12个月	基准情景下经济放缓但避免衰退
历史正常水平	~20%	—	经济扩张期基线概率

上表揭示了机构间预测的分歧主要在悲观与温和之间，而非是否存在风险。穆迪、威尔明顿信托和EY-Parthenon的预测均显著高于历史正常水平（约20%），表明政策不确定性已经实质性侵蚀了经济韧性。高盛30%的预测虽然在五家机构中最低，但仍比正常水平高出50%。值得注意的是，Polymarket作为去中心化预测市场，其41%的共识价格反映了全球参与者的”真金白银”判断，与主流机构的悲观预测高度吻合。

8.3.2 AI泡沫破裂、贸易政策冲击和地缘政治危机的三重威胁

当前美国经济面临的风险并非单一因素驱动，而是三个高度相关冲击源的叠加。第一重威胁是AI泡沫本身。浦银国际2026年中期展望指出，AI投资已成为美国经济的最大驱动力，超大规模云厂商2026年资本支出合计达7,200亿-8,300亿美元。Goldman Sachs估计AI相关资本支出在2025年为GDP增长贡献了约0.6-0.8个百分点。这意味着AI投资是支撑经济避免衰退的重要支柱，但也意味着一旦AI泡沫破裂，经济将同时失去关键的增长引擎。

第二重威胁是贸易政策的累积效应。关税推升通胀、抑制企业投资的传导链条已经启动。核心PCE连续4个月超3%，消费者信心指数下滑，企业固定资产投资增速放缓——这些正是经济从扩张转向收缩的典型前兆。

第三重威胁是地缘政治危机通过大宗商品价格冲击经济。中东冲突持续推高油价，进而加剧通胀压力、强化美联储鹰派立场。然而，这一链条也存在反向可能：若霍尔木兹海峡在2026年下半年重开，油价回落将直接缓解全球通胀压力，美联储降息预期重新升温，美债收益率下行。世界银行预测2026年下半年布伦特原油均价将回落至86美元/桶。

三重威胁之间存在危险的内生性关联：AI泡沫破裂→科技股暴跌→消费和投资者信心崩溃→经济衰退→企业削减CAPEX→半导体需求暴跌→产业链危机。印度经济调查2026引用IMF数据警告，全球科技公司将超1,200亿美元数据中心支出移至表外，若这些项目未能产生预期回报，偿还债务可能变得困难，进而引发市场不稳定。经济调查甚至估计有10%-20%概率发生类似或比2008年更严重的全球危机。

对于投资者而言，需要区分“AI基建泡沫”与“AI技术价值”两个不同概念。泡沫破裂可能消灭过度杠杆的基建公司，但底层技术仍将继续创造价值——正如光纤泡沫破裂后，97%的光纤虽一度闲置，却成为互联网应用爆发的基础设施基础。当前宏观环境的不确定性意味着，即便AI技术本身具有变革性，其资本市场的定价过程也可能经历剧烈的调整。

8.4 AI核武器化：Fable 5出口管制与全球分裂

8.4.1 Anthropic Fable 5事件：AI首次被当作核武器管制

2026年6月12日下午5时21分，美国东部时间，一封来自商务部长霍华德·卢特尼克（Howard Lutnick）的函件送达Anthropic首席执行官达里奥·阿莫迪（Dario Amodei）的办公桌。函件内容简洁而震撼：依据国家安全授权，美国政府发出出口管制指令，要求Anthropic立即暂停其两款最先进基础模型——Fable 5与Mythos 5——对所有外国人士的访问权限，无论这些外国人身处美国境内还是境外，甚至包括Anthropic自己的外籍员工。Anthropic在数小时内被迫关闭了两款模型的全球访问，此时距Fable 5公开发布仅三天。

这是人类历史上首次将AI基础模型当作核武器技术一样进行出口管制——不是通过漫长的立法程序，也不是经由公开的技术标准制定，而是凭借一封部长函件、援引未公开详情的“国家安全关切”，便让一款已部署给数亿商业用户的软件产品瞬间全球下线。

事件的直接导火索，据Axios报道，是另一家公司声称找到了“越狱”（jailbreak）Mythos 5的方法，能够绕过模型的安全防护。Anthropic在声明中对此表示异议，指出政府仅提供了口头证据，所谓越狱技术“狭窄且非普适”，仅涉及让模型读取特定代码库并修复已知软件漏洞——这一能力在OpenAI的GPT-5.5等已公开模型中同样可得。Anthropic更警告称，若以如此标准衡量，整个前沿AI行业的新模型发布都将陷入停滞。

然而，比起技术层面的争议，此事的深层意义在于它所开创的先例：美国政府首次将出口管制这一传统上用于实体商品（如半导体、武器系统）的监管工具，直接应用于数字化的AI模型权重访问权。“国内转让”（domestic transfer）条款意味着，即便坐在美国境内的外国籍工程师也可能触发管制——这在软件行业尚无先例的合规难度。

这一事件并非孤立发生。早在四个月前，Anthropic与美国军方的冲突已急剧升级。2026年2月24日，国防部长皮特·赫格塞斯（Pete Hegseth）在与阿莫迪的会晤中下最后通牒：Anthropic必须允许军方“无任何限制地使用”其AI模型，否则将面临《国防生产法》（Defense Production Act）的强制手段。2月27日，五角大楼正式将Anthropic列入“供应链风险”（supply-chain risk）黑名单——这一标签通常保留给外国敌对实体，此前从未应用于一家美国公司。特朗普同日下令所有联邦机构立即停止使用Anthropic技术。

更具讽刺意味的是，就在五角大楼将Anthropic列入黑名单的同时，同属国防体系的国家安全局（NSA）却正在使用Anthropic受限制的最强模型Mythos Preview参与Project Glasswing网络安全项目。这种矛盾恰恰说明，AI模型管制的核心并非技术安全问题，而是权力博弈——谁有权决定AI的用途与流向。

表8-4 AI出口管制时间线（2022 – 2026年关键事件）

时间	事件	影响范围
2022年10月	美国商务部首次对华实施先进半导体出口管制，限制高性能GPU对华销售	限制NVIDIA A100/H100等芯片对华出口
2023年10月	管制升级，扩大受控芯片范围，增加性能密度门槛	NVIDIA推出降级版H800/A800应对
2025年1月13日	拜登政府发布《AI扩散框架》临时最终规则，将限制从中国扩展至全球	建立三级分层体系：盟友/其他国家/敌对国家
2025年4月	Anthropic提交正式意见，“强烈支持”AI扩散框架，呼吁进一步收紧	AI公司与芯片制造商立场公开分裂
2025年5月13日	BIS废除AI扩散规则，转而发布GP10指导，全球禁用华为昇腾910B/C/D	任何人在全球任何地方使用华为昇腾芯片均可能违反美国出口管制
2025年9月5日	Anthropic更新服务条款，禁止受中国等“敌对国家”控制的实体使用其服务	将管控从地理限制扩展至所有权控制
2026年1月	阿莫迪在达沃斯论坛将出口AI芯片比作“向朝鲜出售核武器”	AI公司高管公开支持最严格的芯片出口管制
2026年1月14日	特朗普宣布对“受覆盖AI芯片”征收25%从价关税	不销往美国供应链的先进AI芯片面临额外成本
2026年2月24 – 27日	五角大楼向Anthropic下最后通牒，随后将其列为“供应链风险”	首个美国AI公司被列入此黑名单
2026年3月9日	Anthropic起诉五角大楼，挑战黑名单决定的合法性	微软提交法庭之友书状支持Anthropic
2026年6月9日	Anthropic发布Fable 5与Mythos 5，为其最强公开模型	Fable 5上线首日即被用于5000万行代码迁移
2026年6月12日	美国商务部发出出口管制指令，全球禁用Fable 5与Mythos 5	史上首次将AI基础模型纳入出口管制

上述时间线揭示了一个清晰的升级脉络：从限制芯片实体出口，到限制全球AI芯片使用，再到直接管制模型本身的访问权，美国的AI管制策略在不到四年内完成了从“硬件边界”到“软件边界”的跨越。值得关注的是，Anthropic在这一进程中扮演了矛盾的双重角色——它既是出口管制最积极的企业支持者，又成为首个因拒绝

配合军方而被制裁的美国AI公司，最终还成为首个被出口管制锁定的基础模型提供商。这种命运的戏剧性转折，折射出AI在国家安全叙事中被迅速“武器化”的深层逻辑。

8.4.2 全球AI格局：正在形成两个阵营

Fable 5出口管制事件不是终点，而是全球AI供应链加速分裂的最新里程碑。一条清晰的技术铁幕正在落下，将世界划分为以美国和中国为中心的两个互不相容的AI生态系统。

美国阵营以NVIDIA、AMD、Intel的先进制程芯片为硬件底座，以OpenAI、Anthropic、Google的闭源基础模型为软件核心。即便在中国市场份额从四年前的95%暴跌至2025年中期的约50%，NVIDIA仍在全球数据中心GPU市场占据约80–85%的绝对主导地位。这一阵营的核心战略，是通过出口管制维持算力优势的代际差——Anthropic在其提交给商务部的正式评论中估计，到2027年，使用受限旧芯片的国家将面临比使用最先进美国芯片高出十倍的AI训练成本。

中国阵营则以华为昇腾910B/C/D系列为硬件支柱，以百度文心、阿里通义、字节豆包和DeepSeek等国产模型为软件生态。摩根士丹利2026年5月发布的研究显示，中国AI芯片（以GPU为主）国产化率已从2021年的10%跃升至2026年的41%，并预计将在2030年达到86%。华为计划在2026年将昇腾910C产量翻倍至约60万颗，联合寒武纪、海光等厂商合计贡献160–170万颗高性能AI芯片。

然而，两个阵营之间并非简单的平行竞争。2025年5月13日，美国商务部BIS发布GP10指导文件，宣布华为昇腾910B、910C、910D“被推定违反出口管制”，全球任何地方的美国或非美国人士使用、销售、转让、融资或服务这些芯片都将面临BIS执法行动。这是美国首次将其出口管制的“长臂”从实体商品贸易延伸至全球范围内的芯片使用行为——一家德国公司在德国数据中心使用华为昇腾芯片训练模型，理论上即构成违反美国出口管制。

Anthropic在这一格局中选择了明确的立场。2025年9月，Anthropic更新服务条款，禁止任何“受中国等不支持地区控制”的实体使用其服务，包括超过50%股权由中国公司直接或间接持有的海外子公司。同年4月，Anthropic向商务部提交正式评论，“强烈支持”AI扩散框架，称其“对赢得与中国的战略竞争至关重要”。2026年1月，阿莫迪在达沃斯世界经济论坛上更将出口AI芯片给中国的政策比作“向朝鲜出售核武器然后吹嘘波音制造了弹壳”。

这种公开倡导严格管制的立场，使Anthropic与NVIDIA形成了鲜明对立。NVIDIA CEO黄仁勋多次公开批评出口管制政策，称NVIDIA在中国的份额已从95%跌至“接近于零”，“我无法想象任何政策制定者会认为这是一件好事”。黄仁勋更将管制政策称为“失败”，因为其基本假设“完全错误”。芯片制造商关心的是市场规模与营收，AI模型公司关心的是地缘战略优势——两者的利益分歧日益尖锐。

在两个大国之间，第三阵营（中东、欧洲、东南亚各国）被迫面临痛苦抉择。沙特阿拉伯、阿联酋等海湾国家虽被美国列为Tier 1盟友享有芯片采购便利，但其与中国的科技合作关系使其陷入两难。欧洲国家则在数字主权与跨大西洋联盟之间摇摆——一方面渴望摆脱对美国云服务的依赖，另一方面又不希望在AI竞赛中被完全排除在美国技术生态之外。新加坡、印度等Tier 2国家面临更严峻的限制：2025–2027年间，每个国家最多仅能获得约5万块GPU的免审配额。

8.4.3 对半导体需求的短期冲击

AI被“核武器化”的直接经济后果，是对全球半导体需求曲线的扭曲与扰动。

从短期视角看，出口管制对美国半导体公司构成了显著的需求损失。NVIDIA在中国的直接销售份额已从四年前的95%降至接近零。2025年H20芯片被禁事件导致NVIDIA计提55亿美元库存损失，全年因中国出口管制造成的收入影响估计达100亿美元，约占其总营收的5%。尽管NVIDIA通过Blackwell架构产品的强劲需求部分抵消了这一损失，但中国作为“全球第二大计算市场”（黄仁勋语）的完全丧失，对任何半导体公司而言都不是可忽视的缺口。

更深层的冲击在于需求结构的改变。在管制之前的全球化时代，中国公司可以通过采购美国芯片或直接使用AWS、Azure、GCP等美国云服务来获取算力——这意味着中国的AI算力需求一定程度上由美国的半导体供给来满足。随着管制层层加码，中国被迫转向建设完全自主的AI基础设施——从芯片设计（华为昇腾、寒武纪）到晶圆制造（中芯国际）再到云服务（阿里云、腾讯云、华为云）。摩根士丹利估计，到2026年，仅中国本土高性能AI推理芯片的供应量就将达到约300万颗（不含互联网巨头自研芯片）。

但这种替代并非瞬间完成。华为昇腾芯片在单芯片性能上仍大幅落后——即将推出的昇腾950在性能上仅相当于NVIDIA下一代VR200超级芯片的6%。中芯国际的7纳米DUV工艺需要多重曝光，步骤数是EUV的三倍以上，良率持续承压。在HBM高带宽内存领域，中国长鑫存储（CXMT）的HBM3良率约为50%，而韩国三星、SK海力士已进入第六代HBM4量产阶段。这意味着中国半导体自给自足的进程虽然加速，但短期内面临性能差距与产能瓶颈的双重制约。

这对全球半导体市场的中期影响值得警惕。当前全球AI基础设施投资热潮的一个关键假设，是算力需求将无限扩张——每一家大型科技公司都在以前所未有的速度采购GPU、建设数据中心。然而，如果全球AI市场因技术铁幕而分裂为两个互不流通的区域市场，全球总算力需求的算术天花板将下降。中国市场原本对美国半导体公司贡献的需求增量，现在被迫转向国产替代；而中国市场所需的国产芯片产能，又需要数年时间才能充分释放。在这一“需求真空期”内，全球算力供给过剩的风险正在累积。

这一逻辑指向一个关键推论：AI出口管制正在加速当前AI基础设施泡沫的供需平衡拐点。当全球AI需求被人为分割，而供给侧（以NVIDIA Blackwell、AMD MI350、华为昇腾950为代表）继续按计划扩张时，某种形式的“算力过剩”将不再是远期假设，而是中期现实。

8.4.4 AI变成国界化技术的长远影响

将AI“核武器化”的最深远影响，不在于某一季度的营收损失或某一款模型的下线，而在于它从根本上改变了AI作为一项技术的属性与发展轨迹。

在开放互联网时代的预设中，AI是全球化技术的终极体现——算法无国界，模型可在任何有网络连接的地方运行，权重文件可以被复制到任何硬件上。但Fable 5出口管制事件宣告了这一预设的终结。AI正在从“全球化技术”蜕变为“国界化战略资产”，其扩散逻辑日益接近核武器——拥有者不想让其他人拥有，而管制手段也在不断向核不扩散体系靠拢。

这一转变对产业链的影响是多维度的。首先，全球统一的AI市场将分裂为多个区域市场。美国市场使用NVIDIA/OpenAI/Anthropic技术栈，中国市场使用华为昇腾/百度文心/阿里通义/DeepSeek技术栈，中间地带则被迫在两者之间做出选择或同时维持两套系统。这种分裂意味着全球范围内的AI应用互操作性下降、开发成本上升、创新网络被切割。一家在中国运营的美国企业可能需要同时维护两套AI基础设施——一套用于国内业务（合规要求），一套用于国际业务（性能需求）——类似今天许多跨国公司必须同时运营AWS与阿里云的双重架构，但程度将深得多。

其次，技术标准的分裂将自我强化。DeepSeek选择在华为昇腾910C上优化其V4模型是一个标志性事件——这些优化使用了CANN框架的自定义算子和华为特有的HCCS通信协议，完全不可迁移至NVIDIA硬件。这种“硬件-软件”的深度绑定意味着，一旦某个AI生态选择了某一技术栈，迁移成本将高到足以锁定其长期选择。久而久之，两个阵营将发展出互不理解的技术语言，正如冷战时期苏联的度量衡体系与西方世界渐行渐远。

对投资者而言，这一格局变化具有深刻的估值含义。全球化的AI公司估值需要打折，区域龙头将获得溢价。一家在中国运营的AI公司，如果其技术栈完全依赖美国硬件和模型，其业务连续性风险将显著上升——Fable 5事件证明，美国政府可以在一夜之间让一款模型全球下线。反之，拥有完整国产技术栈的中国AI公司，虽然单点性能可能落后，却因“不可替代性”而获得战略溢价。同样，能够在两个阵营之间充当“桥梁”的第三国（如拥有自主芯片制造能力的韩国、拥有中立数字主权框架的瑞士）也可能获得特殊的地缘套利机会。

最后，也是最根本的，AI“核武器化”将改变技术创新的激励结构。在开放竞争环境中，性能最优的模型赢得市场；在分裂环境中，政治忠诚度与地缘安全考量将与技术性能同等重要——甚至更为重要。当Anthropic选择拒绝五角大楼的要求而宁愿承受黑名单制裁时，它实际上是在用商业利益换取道德立场；而当OpenAI迅速与五角大楼签署包含更宽松条款的机密网络合作协议时，两家公司不同的选择将深刻影响它们各自的政府合同前景与国际市场信誉。在这个新世界中，AI公司的CEO不仅需要是技术专家和企业家，还必须成为地缘战略家——能够在一个将AI视为国家安全核心资产的世界中 navigate 日益复杂的利益冲突。

从更宏观的视角审视，AI正在重演20世纪核技术的发展轨迹：从科学突破到军备竞赛，从技术扩散到管制体系，最终形成一个被少数国家垄断、受严格国际协议约束的战略能力。不同之处在于，核武器的制造需要举国体制的工业投入和高度可见的物理设施，而AI模型的训练和部署可以在数据中心中静默完成——这使得管制更加困难，也更具侵略性。Fable 5事件所开创的“部长函件即可让全球模型下线”的先例，预示着一个更频繁、更不可预测的管制时代的到来。在这个时代中，AI基础设施投资的风险收益计算必须纳入一个新的变量：地缘政治中断风险。而这一风险，恰恰是所有当前AI估值模型中最难以量化、却最具破坏力的因素。

9. 未来展望：AI应用爆发与下一个赢家

9.1 AI应用商业化加速

2026年正在成为AI应用层从“实验期”跨入“商业化兑现期”的关键拐点。如果我们将2023—2024年定义为“模型能力竞赛”阶段，那么2025—2026年的主题已经转向“收入兑现”——而编程助手正是最先跑通商业化闭环的品类。

GitHub Copilot在2026年1月达到470万付费用户，同比增长75%，年化经常性收入（ARR）约为8.5—10亿美元。更为瞩目的是后来者Cursor的崛起：这家成立于2023年的AI代码编辑器在2026年初ARR突破20亿美元，估值飙升至293亿美元；与此同时，Claude Code在2026年2月录得25亿美元年化收入，成为Anthropic整体47亿美元年化收入中增长最快的产品线。Windsurf（原Codeium）在2026年第一季度亦达到24亿美元ARR。四款产品的合计年化收入已超过70亿美元，且开发者渗透率仍在快速攀升——84%的开发者已使用或计划使用AI编程工具，51%的专业开发者每日使用。

企业级AI Agent市场同样在2026年迎来爆发。Gartner预测，到2026年底将有40%的企业应用嵌入任务型AI Agent，而这一比例在2025年初尚不足5%。全球AI Agent市场规模预计从2025年的76—79亿美元扩张至2026年的109—121亿美元，复合年增长率达44—46%。微软在这一领域展现出压倒性的渠道优势：超过16万个组织部署了逾40万个Copilot Studio Agent，约85%的财富500强企业已使用至少一款微软AI产品。Salesforce Agentforce在FY26录得8亿美元ARR（同比增长169%），累计达成2.9万笔交易；ServiceNow则将2026年AI收入目标上调至15亿美元。

中国市场的商业化步伐同样加速。字节跳动旗下豆包月活用户已达3.45亿、日活突破1亿，日均Token消耗量高达120万亿，用户规模相当于第二至第五名的总和。2026年5月，豆包启动付费订阅测试，标准版定价每月68元——这标志着字节从大规模补贴向可持续商业模式的战略转折。通义千问上线两个月月活即破1亿，深度整合淘宝、饿了么、支付宝等阿里生态，摩根士丹利预计60%—70%的数字场景任务未来将由AI自主完成。

9.2 谁是AI时代的大赢家？——从互联网基建泡沫的历史镜鉴说起

市场热衷于追问“谁将是AI时代的腾讯”——但这个设问本身可能就错了。回溯上一轮技术革命，答案从来不是“下一个谁”，而是“下一批谁”。

互联网基建泡沫的教训：赢家是一群，不是一个

1999—2000年的光纤基建泡沫与今天的AI算力泡沫有着惊人的结构性相似。彼时，全球电信运营商和光纤铺设公司在两年间烧掉了约2000亿美元资本开支，铺设了足以环绕地球数千圈的光纤容量。泡沫破裂后，大多数基建公司破产或市值蒸发90%以上，但廉价的基础设施却催生了一整代互联网巨头。

Google（1998年创立，2004年IPO）是这场基建红利中最大的赢家。它并非光纤铺设者，而是最善于利用廉价带宽和计算能力的应用层公司。从IPO时的230亿美元市值到如今的2万亿美元以上，Google的崛起建立在一个核心洞察之上：当基础设施变得足够便宜，在之上构建智能应用的公司将捕获超额价值。

Amazon（1994年创立）走出了一条不同的路径。它在泡沫破裂后的废墟中以极低成本获取了数据中心容量和带宽，最终将这些能力外化为AWS——如今AWS贡献了亚马逊超过60%的运营利润，成为全球云计算的基石。

阿里巴巴（1999年创立）和腾讯（1998年创立）则是中国版图的赢家。阿里以电商为起点，延伸至支付（支付宝）和云计算（阿里云）；腾讯则以社交为根基，在游戏和移动支付上构建了庞大的生态帝国。值得注意的是，腾讯的真正崛起更多依托于2009年后的移动互联网基建（4G网络、智能手机普及），而非光纤泡沫本身——这进一步说明，每一轮基建周期都会孕育属于自己的赢家群像。

此外，Netflix（1997年创立，从DVD租赁转型流媒体）和eBay（1995年创立）同样诞生于同一时期。它们并非基础设施公司，而是善于在成本不断下降的带宽和计算能力之上重构商业模式的“应用层创新者”。

历史给出的教训清晰而有力：基建泡沫破裂后的最大赢家，从来不是基建公司本身，而是那些能够在廉价基础设施之上构建应用、形成生态闭环的平台型企业。不是“下一个腾讯”——而是“下一批Google、Amazon、阿里巴巴和腾讯”。

AI时代的赢家群像：生态护城河决定终局

当前AI产业的竞争格局正在复刻互联网时代的规律。已经拥有分发渠道、用户生态和数据飞轮的平台型公司，正在展现出难以逾越的结构性优势。超大规模云服务商（Microsoft、Salesforce、ServiceNow、Google）已经捕获了绝大多数企业级AI Agent的灯塔客户部署，因为它们“现有的应用足迹提供了分发渠道”。

下表将AI时代的主要竞争者与其在互联网时代的对标者进行系统比较：

公司	核心生态优势	对标互联网时代的谁	关键差异化因素
Microsoft	Copilot + Office 365 + Azure + 85%财富500强覆盖率	Microsoft（自己就是赢家）	企业渠道无可撼动，1200万Copilot付费席位
Google	Gemini + Search + Cloud + Android	Google（自己就是赢家）	搜索流量入口+模型自研能力，但面临反垄断拆分风险
字节跳动	豆包3.45亿月活 + 抖音/TikTok + 火山引擎	阿里巴巴（超级平台模式）	流量分发能力全球顶尖，但商业化路径仍在探索
Meta	Llama开源生态 + WhatsApp + Instagram + Facebook	Facebook（社交帝国）	开源策略降低模型成本，社交关系链构成天然Agent分发网络
阿里巴巴	通义千问 + 淘宝/天猫 + 支付宝 + 阿里云	阿里巴巴（自己就是赢家）	“需求-服务-支付”全链路闭环，纯AI工具难以复制
Amazon	AWS + Alexa + 电商	Amazon（自己就是赢家）	云计算利润引擎支撑AI投入，但消费端AI存在感偏弱

上表揭示了一条清晰的规律：AI时代的赢家候选人，无一例外都是“自带生态”的选手。它们不需要从零获取用户——它们的AI产品天然拥有数十亿级的分发入口。这与互联网泡沫后的赢家图谱高度一致：Google拥有搜索流量，Amazon拥有电商用户，腾讯拥有社交网络，阿里巴巴拥有交易场景。

一个值得警惕的差异在于，AI时代新创公司的窗口期可能比互联网时代窄得多。在互联网泡沫后的五年至十年间，创业公司尚有充裕时间成长为巨头；而在AI时代，大厂的生态护城河更深、模型迭代速度更快、资本集中程度更高——2026年第一季度，全球前四大AI公司吸收了63%的全部风险投资。垂直领域的新创公司如

Cursor（编程）和Sierra（客服Agent）或许仍有机会在细分领域突围，但通用型AI应用的创业窗口可能仅有2—3年。

反面视角：赢家的不确定性

尽管平台巨头胜算最大，历史并非简单重复。Google在互联网时代击败了Yahoo和Altavista，但它在AI时代面临的竞争格局远为复杂——OpenAI和Anthropic在模型能力上并不逊色，且监管压力可能迫使Google拆分。字节跳动拥有流量优势，但豆包面临“用户越多、亏损越大”的推理成本困境：3.45亿月活背后，日均120万亿Token的消耗正在侵蚀利润。中国的AI赢家可能最终不是豆包，而是能够将AI深度嵌入交易闭环的阿里巴巴，或是借社交关系链实现病毒式扩散的腾讯元宝。

Gartner预测超过40%的AI Agent项目可能在2027年前被取消，仅25%的AI计划实现了预期ROI。这意味着即便生态型巨头也并非稳赢——它们同样需要穿越从“试点”到“规模化”的死亡之谷。

9.3 投资策略建议

基于上述分析，我们为不同风险偏好的投资者提出以下策略框架：

做空/回避：纯AI基础设施提供商。CoreWeave、Credo等高估值的算力租赁和半导体设备公司，在当前基建泡沫中定价最为脆弱。一旦资本开支周期转向，这些公司的收入增速可能急剧放缓，而高运营杠杆将放大下行风险。历史参照：2000—2002年间，光纤设备商JDS Uniphase和Lucent的市值蒸发均超过95%。

持有：已有生态护城河的平台巨头。Microsoft（Copilot + Office + Azure的企业级飞轮）、Google（搜索流量 + Gemini + Cloud，尽管面临反垄断风险）、Meta（开源Llama降低模型成本 + 社交分发网络），以及中国的字节跳动（若上市）和阿里巴巴。这些公司在基建泡沫破裂后反而将受益于算力成本的下降——当GPU从稀缺品变为大宗商品，拥有应用场景的公司将捕获价格下降的全部红利。

等待抄底：AI应用层公司。当前AI-native SaaS公司的估值倍数高达12—20倍，远超传统SaaS的4—5倍中位数。但泡沫破裂后将出现极佳的入场时机。重点关注两类标的：一是已经验证ROI的垂直领域Agent（如客服Agent的中位数ROI为3.2倍），二是拥有数据飞轮效应的企业（如Databricks以54亿美元ARR和正自由现金流的盈利规模）。

新增关注：“AI效率提升”受益股。如果本轮AI基建泡沫导致算力供给严重过剩（类似2000年后的光纤带宽过剩），谁会从廉价的AI算力中受益最多？三个方向值得布局：一是内容平台公司（AI降低内容生产成本），二是软件服务公司（AI降低研发和服务交付成本），三是数据密集型行业（金融、医疗、法律）中善于利用AI提升人效的传统龙头。它们的共同特征是：不需要自己拥有AI基础设施，只需要善于调用最便宜的算力来提升核心业务效率。

最终，历史不会简单重复，但它押韵。互联网基建泡沫后，最大的赢家不是康宁（光纤制造商）和世通（电信运营商），而是Google、Amazon、阿里巴巴和腾讯——那些善于在廉价基础设施上构建应用生态的平台。AI时代的大赢家，大概率也将遵循同一剧本。

10. 结论：泡沫会破，但AI不会死

10.1 核心结论

SpaceX S-1文件首次揭开了AI公司的财务真相。2026年5月，首次将AI前沿模型的财务真相暴露在公开市场之下。xAI（现SpaceXAI）2026年Q1营收8.18亿美元，运营亏损24.7亿美元，亏损/收入比高达3.02:1。这意味着每创造1美元收入，xAI需要烧掉超过3美元。PitchBook分析师Harrison Rolfes的评价一针见血：“如果与传统SaaS公司比较，这些财务数据看起来是鲁莽的”。而SpaceX的Q1资本支出中，AI部分独占77亿美元，是火箭业务（10.5亿美元）的7.3倍。这不仅是马斯克一个人的豪赌——它是整个AI产业链资金流向的缩影。

CAPEX增速见顶回落的精确时点预测。当前云厂商资本支出的增速仍处于上升通道，但拐点正在逼近。Goldman Sachs与BloombergNEF预测，2026年五大云厂商合计CAPEX将超过6000亿美元，同比增长约36%，其中IDC预测AI专用基础设施支出约4870亿美元（同比+53%）。这意味着增速本身仍在加速。然而，Barclays的预测模型显示，虽然绝对金额将从2026年的7850亿美元攀升至2027年的1.16万亿美元，但同比增速将显著放缓。我们判断2027年Q2-Q3财报季是第一个高风险窗口：当连续两个季度CAPEX同比增速出现下降时，市场将意识到“永远增长”的叙事已经终结。成长股估值的数学基础是增速溢价——当增速放缓时，40-60倍市盈率的合理性将瞬间崩塌。

三大黑天鹅可能加速破裂。第一种是AI递归自我改进导致的算力需求意外崩溃。Anthropic CEO Dario Amodei预测超人类水平的AGI可能在2026-2027年出现，如果模型能够自主优化自身架构，当前以千亿美元计的训练投入将面临“断崖式”贬值。第二种是AI核武器化——Fable 5出口管制全面升级导致全球市场分裂，中美科技脱钩已使NVIDIA在华份额从95%跌至55%，若管制进一步收紧，全球算力供给格局将彻底重组。第三种是宏观环境恶化：10年期美债收益率维持在4.45%-4.56%的高位，特朗普关税政策的反复已使“科技七巨头”在2025年4月两日之内蒸发1.8万亿美元市值。57%的机构已将“科技泡沫破裂”列为2026年最大风险。

历史规律高度一致。1990年代末的光纤泡沫留下了2万亿美元损失，97%的光纤一度闲置——但那些光纤后来成了Google和Amazon的数据高速公路。19世纪的铁路泡沫使股价暴跌85%，但90%的现代英国铁路网来自那个时代的建设。移动互联网基建期，电信运营商烧掉数千亿，最终腾讯和阿里巴巴捕获了最大的价值。本轮AI基建泡沫的终局不会不同：过度建设的算力基础设施最终将成为下一代平台巨头的温床。Microsoft、Google、字节跳动——这些同时拥有生态优势和AI基础设施的平台型企业，最有可能在泡沫压缩后脱颖而出。

10.2 给投资者的行动框架

监控三个领先指标。第一，CoreWeave股价。作为第一家纯AI基础设施上市公司，CoreWeave是整个板块的“煤矿中的金丝雀”。其股价从52周高点187美元跌至95.74美元（2026年6月11日），空头头寸高达5460万股、占流通股的12.20%，Q1营收21亿美元但GF Score仅18/100——这些信号不容忽视。若CoreWeave信用评级遭下调或再融资受阻，可能触发整个产业链的信心危机。第二，CAPEX增速拐点。追踪四大云厂商每季度CAPEX同比增速，当连续两个季度增速下降时，即为泡沫进入高风险期的量化信号。第三，GPU租赁价格。H100一年期租赁价格已从2025年10月的1.70美元/小时飙升至2026年3月的2.35美元/小时（+40%），这种价格的不可持续性恰恰是供需拐点的反向指标。

区分“AI基建泡沫”与“AI技术价值”。做空前者，做多后者。AI基建泡沫的本质是一场关于算力供给的军备竞赛，参与者（云厂商）被迫借债数千亿美元投入CAPEX，AI收入却仅250-433亿美元，CAPEX覆盖率仅4-7%。这种模式高度依赖资本市场的持续输血——新融资主要用于覆盖既有投入、而非由超额回报自我维持，其可持续性取决于资本耐心。但AI技术本身的价值是真实的：AI Agent市场2026年预计达109-121亿美元，字节豆包月活已达3.45亿。泡沫破裂不会消灭技术，只会消灭过度杠杆。

2027年Q2-Q3是第一个关键观察窗口（若RPO增速未放缓则延至2028年H1）。届时云厂商将发布2027年上半年财报，CAPEX增速是否出现拐点将一目了然。若增速从2026年的60-88%降至35-40%区间，高估值科技股将面临系统性重估。最可能的情景不是2000年式的崩盘，而是2027-2029年的“缓慢修正”——估值压缩30-50%，部分项目取消，但不会出现系统性金融危机。区别在于，本轮泡沫的资助者（五大科技巨头）拥有远超当年电信运营商的财务实力——总运营现金流超5000亿美元。

泡沫破裂后，重仓平台型公司。历史经验表明，基础设施泡沫破裂后的最大赢家，永远是能够利用廉价基础设施构建应用生态的平台企业。在AI领域，Microsoft（Microsoft 365 Copilot、Azure OpenAI服务）、Google（Gemini、Workspace AI）、字节跳动（豆包、抖音AI）——这些公司同时拥有C端入口和算力基础设施，最可能在泡沫压缩后捕获双层价值。而CoreWeave、部分光模块公司和纯GPU租赁商，可能面临最大风险——它们的商业模式完全依赖于CAPEX增速的持续向上。

最终，AI泡沫的终局可以用一句话概括：泡沫和技术的价值是两个不同的问题。光纤泡沫破裂了，但互联网来了；移动基建烧完了，但腾讯崛起了；AI基建泡沫终将破裂，但AI革命不会停止。对于投资者而言，关键不是押注泡沫是否破裂——它终将破裂——而是在正确的时点，站在正确的一边。

免责声明

本报告仅供参考，不构成投资建议。

本报告中的信息和观点均基于公开数据和作者分析，不保证其完整性、准确性或及时性。投资者应独立做出投资决策，并自行承担投资风险。

报告中的预测和判断基于当前可获取的信息，实际市场走势可能与预测存在重大差异。过往表现不代表未来收益。

本报告版权归作者所有，未经授权不得转载或引用。

报告完成日期：2026年6月

赵世豪 · Shihao Zhao

ShihaoSights · AI 洞察

公众号 ShihaoSights

官 网 shihao.uk

读懂 AI，跑在前面